



Mémoire de L3 Magistère

Étude des modèles génératifs pour la génération d'images

par
Maël COLIN

encadré par
Mathias DUS

2026

Table des matières

1	Introduction	2
2	Rappels de probabilité	2
3	Mise en contexte	6
4	Schéma à suivre	6
5	Modèles de Diffusion	7
5.1	Score-based Generative Models	7
5.1.1	Définitions	7
5.1.2	Obtention du processus de génération	11
5.1.3	Entraînement	15
5.1.4	Démonstration du Denoising Score Matching	15
5.1.5	Détermination de $\sigma(1)$	19
5.1.6	Détermination de $\sigma(0)$	23
5.1.7	Détermination de $\sigma(t)$	24
5.1.8	Implémentation du modèle	25
5.2	Probability Flow	29
5.2.1	Obtention du processus de génération	29
5.2.2	Différence entre les modèles SGM et Probability Flow	32
6	Modèles de Flot	33
6.1	Flow Matching	33
6.1.1	Obtention du processus de génération	33
6.1.2	Entraînement	37
6.1.3	Démonstration du Conditional Flow Matching	38
6.1.4	Couplage décorrélé	40
6.1.5	Couplage corrélé	42
6.1.6	Rectified Flow Matching	44
7	Comparaison des modèles	46
8	Conclusion	49

1 Introduction

La génération d'images par intelligence artificielle a connu un essor considérable ces dernières années. Des outils tels que *DALL-E*, *Midjourney*, *Stable Diffusion* ou encore *Flux* sont désormais capables de produire des images réalistes à partir d'une simple description textuelle. Ces performances reposent sur des modèles génératifs capables d'apprendre la distribution des images afin d'en générer de nouvelles.

Les modèles de diffusion se sont imposés comme une référence dans ce domaine grâce à leur grande qualité de génération. Leur principe consiste à apprendre à inverser un processus de bruitage progressif des images [1, 2, 3]. Plus récemment, les modèles de flot ont été proposés comme une alternative prometteuse. En apprenant directement un champ de vitesses reliant une distribution simple à la distribution des données, ils permettent une génération plus rapide tout en conservant des performances comparables [4, 5, 6].

L'objectif de ce mémoire est de présenter les fondements mathématiques de ces deux familles de modèles. Nous étudierons d'abord les modèles de diffusion avant de présenter les modèles de flot. Enfin, nous comparerons expérimentalement ces différentes approches.

2 Rappels de probabilité

Définition 2.1 (Espace probabilisable). *Un espace probabilisable est un couple $(\Omega, \mathcal{A})$ où :*

- Ω est un ensemble appelé univers ;
- $\mathcal{A}$ est une tribu sur Ω , c'est-à-dire une famille de parties de Ω telle que :
 1. $\Omega \in \mathcal{A}$;
 2. si $A \in \mathcal{A}$, alors $A^c \in \mathcal{A}$;
 3. pour toute suite $(A_n)_{n \geq 1}$ d'éléments de $\mathcal{A}$,

$$\bigcup_{n=1}^{\infty} A_n \in \mathcal{A}.$$

Les éléments de $\mathcal{A}$ sont appelés événements.

Définition 2.2 (Mesure de probabilité). *Soit $(\Omega, \mathcal{A})$ un espace probabilisable. Une mesure de probabilité est une application*

$$\mathbb{P} : \mathcal{A} \longrightarrow [0, 1]$$

vérifiant :

1. $\mathbb{P}(\Omega) = 1$;
2. pour toute suite $(A_n)_{n \geq 1}$ d'événements deux à deux disjoints,

$$\mathbb{P}\left(\bigcup_{n=1}^{\infty} A_n\right) = \sum_{n=1}^{\infty} \mathbb{P}(A_n).$$

Définition 2.3 (Probabilité). *Une probabilité est une mesure de probabilité définie sur une tribu d'événements. Pour tout événement $A \in \mathcal{A}$, le réel $\mathbb{P}(A)$ représente la probabilité que l'événement A se réalise.*

Définition 2.4 (Espace probabilisé). *Un espace probabilisé est un triplet $(\Omega, \mathcal{A}, \mathbb{P})$ où :*

- $(\Omega, \mathcal{A})$ est un espace probabilisable ;
- $\mathbb{P}$ est une mesure de probabilité sur $(\Omega, \mathcal{A})$.

De plus, on définit l'espérance conditionnelle que l'on utilisera tout au long du document :

Définition 2.5 (Espérance conditionnelle). Soit $(\Omega, \mathcal{A}, \mathbb{P})$ un espace probabilisé, $Y \in L^1(\Omega, \mathcal{A}, \mathbb{P})$ une variable aléatoire intégrable et $\mathcal{G} \subset \mathcal{A}$ une sous-tribu.

On appelle espérance conditionnelle de Y sachant $\mathcal{G}$ toute variable aléatoire Z , notée

$$Z = \mathbb{E}[Y \mid \mathcal{G}],$$

vérifiant les deux propriétés suivantes :

1. Z est $\mathcal{G}$ -mesurable ;
2. pour tout ensemble $A \in \mathcal{G}$,

$$\int_A Z \, d\mathbb{P} = \int_A Y \, d\mathbb{P}.$$

On a alors unicité de l'espérance conditionnelle :

Proposition 2.6 (Unicité de l'espérance conditionnelle). Soient $(\Omega, \mathcal{A}, \mathbb{P})$ un espace probabilisé, $Y \in L^1(\Omega, \mathcal{A}, \mathbb{P})$ et $\mathcal{G} \subset \mathcal{A}$ une sous-tribu.

S'il existe deux variables aléatoires Z_1 et Z_2 vérifiant la définition de l'espérance conditionnelle de Y sachant $\mathcal{G}$, alors

$$Z_1 = Z_2 \quad \text{p.s.}$$

Démonstration. Par définition de l'espérance conditionnelle, les variables aléatoires Z_1 et Z_2 sont $\mathcal{G}$ -mesurables et vérifient, pour tout $A \in \mathcal{G}$,

$$\int_A Z_1 \, d\mathbb{P} = \int_A Y \, d\mathbb{P} = \int_A Z_2 \, d\mathbb{P}.$$

Par conséquent,

$$\int_A (Z_1 - Z_2) \, d\mathbb{P} = 0, \quad \forall A \in \mathcal{G}.$$

Posons

$$D = Z_1 - Z_2.$$

Comme Z_1 et Z_2 sont $\mathcal{G}$ -mesurables, D est également $\mathcal{G}$ -mesurable.

Choisissons

$$A = \{D > 0\} \in \mathcal{G}.$$

On obtient alors

$$\int_{\{D > 0\}} D \, d\mathbb{P} = 0.$$

Or, sur l'ensemble $\{D > 0\}$, on a $D > 0$. Il en résulte nécessairement que

$$\mathbb{P}(D > 0) = 0.$$

De même, en prenant

$$A = \{D < 0\} \in \mathcal{G},$$

on obtient

$$\int_{\{D < 0\}} D \, d\mathbb{P} = 0,$$

et comme $D < 0$ sur cet ensemble,

$$\mathbb{P}(D < 0) = 0.$$

Finalement,

$$\mathbb{P}(D \neq 0) = \mathbb{P}(D > 0) + \mathbb{P}(D < 0) = 0,$$

c'est-à-dire

$$Z_1 = Z_2 \quad \text{p.s.}$$

Ainsi, l'espérance conditionnelle est unique à un ensemble de mesure nulle près. □

On a de plus la propriété suivante.

Propriété 2.7. Soit $(\Omega, \mathcal{A}, \mathbb{P})$ un espace probabilisé, $Y \in L^1(\Omega, \mathcal{A}, \mathbb{P})$ une variable aléatoire intégrable et $\mathcal{G} \subset \mathcal{A}$ une sous-tribu. On a alors :

- (i) $\mathbb{E}[\mathbb{E}[Y | \mathcal{G}]] = \mathbb{E}[Y]$
- (ii) Si V est une variable aléatoire $\mathcal{G}$ -mesurable telle que $VY \in L^1$, alors

$$\int_{\Omega} V \mathbb{E}[Y | \mathcal{G}] d\mathbb{P} = \int_{\Omega} VY d\mathbb{P}.$$

- (iii) Si U est une variable aléatoire $\mathcal{G}$ -mesurable telle que $UY \in L^1$, alors

$$\mathbb{E}[UY | \mathcal{G}] = U \mathbb{E}[Y | \mathcal{G}].$$

Démonstration. (i) Par définition de l'espérance conditionnelle, la variable aléatoire

$$W = \mathbb{E}[Y | \mathcal{G}]$$

est $\mathcal{G}$ -mesurable et vérifie

$$\int_A W d\mathbb{P} = \int_A Y d\mathbb{P}, \quad \forall A \in \mathcal{G}.$$

Comme

$$\Omega \in \mathcal{G},$$

on peut choisir $A = \Omega$. On obtient alors

$$\int_{\Omega} W d\mathbb{P} = \int_{\Omega} Y d\mathbb{P}.$$

Or,

$$\int_{\Omega} W d\mathbb{P} = \mathbb{E}[W] = \mathbb{E}[\mathbb{E}[Y | \mathcal{G}]],$$

et

$$\int_{\Omega} Y d\mathbb{P} = \mathbb{E}[Y].$$

Ainsi,

$$\mathbb{E}[\mathbb{E}[Y | \mathcal{G}]] = \mathbb{E}[Y].$$

- (ii) Par définition de l'espérance conditionnelle, la variable aléatoire W est $\mathcal{G}$ -mesurable et vérifie

$$\int_A W d\mathbb{P} = \int_A Y d\mathbb{P}, \quad \forall A \in \mathcal{G}.$$

Pour toute variable aléatoire V , il existe une suite de variables simples $(V_n)_{n \geq 1}$, $\mathcal{G}$ -mesurables telle que

$$\lim_{n \rightarrow \infty} V_n = V \quad \text{et} \quad |V_n| \leq |V|.$$

et pour tout $n \geq 1$, il existe un entier $k_n \geq 1$, des réels $a_1^{(n)}, \dots, a_{k_n}^{(n)}$ et des ensembles $A_1^{(n)}, \dots, A_{k_n}^{(n)} \in \mathcal{G}$ tels que,

$$V_n = \sum_{i=1}^{k_n} a_i^{(n)} \mathbf{1}_{A_i^{(n)}}$$

On a alors par linéarité de l'intégrale,

$$\begin{aligned}
\int_{\Omega} V_n W \, d\mathbb{P} &= \int_{\Omega} \left(\sum_{i=1}^{k_n} a_i^{(n)} \mathbf{1}_{A_i^{(n)}} \right) W \, d\mathbb{P} \\
&= \sum_{i=1}^{k_n} a_i^{(n)} \int_{A_i^{(n)}} W \, d\mathbb{P} \\
&= \sum_{i=1}^{k_n} a_i^{(n)} \int_{A_i^{(n)}} Y \, d\mathbb{P} \\
&= \int_{\Omega} \left(\sum_{i=1}^{k_n} a_i^{(n)} \mathbf{1}_{A_i^{(n)}} \right) Y \, d\mathbb{P} \\
&= \int_{\Omega} V_n Y \, d\mathbb{P}.
\end{aligned}$$

Soit maintenant V une variable aléatoire $\mathcal{G}$ -mesurable, telle que $VY \in L^1$. Il existe une suite de variables simples $(V_n)_{n \geq 1}$ telle que

$$V_n \longrightarrow V \quad \text{et} \quad |V_n| \leq |V|.$$

Comme

$$|V_n W| \leq |VW|,$$

et

$$|V_n Y| \leq |VY|.$$

De plus, puisque $VY \in L^1$ on a $VW \in L^1$.

Ainsi, le théorème de convergence dominée donne,

$$\int_{\Omega} VW \, d\mathbb{P} = \lim_{n \rightarrow \infty} \int_{\Omega} V_n W \, d\mathbb{P}$$

et

$$\int_{\Omega} VY \, d\mathbb{P} = \lim_{n \rightarrow \infty} \int_{\Omega} V_n Y \, d\mathbb{P}.$$

Or, pour tout n on a prouvé que,

$$\int_{\Omega} V_n W \, d\mathbb{P} = \int_{\Omega} V_n Y \, d\mathbb{P}.$$

Ainsi, en passant à la limite, on obtient

$$\int_{\Omega} V \mathbb{E}[Y \mid \mathcal{G}] \, d\mathbb{P} = \int_{\Omega} VY \, d\mathbb{P}.$$

(iii) Comme U et $\mathbb{E}[Y \mid \mathcal{G}]$ sont $\mathcal{G}$ -mesurables, $U\mathbb{E}[Y \mid \mathcal{G}]$ est également $\mathcal{G}$ -mesurable.

Soit $A \in \mathcal{G}$.

Comme U est $\mathcal{G}$ -mesurable, la variable

$$V = \mathbf{1}_A U$$

est elle aussi $\mathcal{G}$ -mesurable. Par (ii) on a donc,

$$\int_{\Omega} V \mathbb{E}[Y \mid \mathcal{G}] \, d\mathbb{P} = \int_{\Omega} VY \, d\mathbb{P}.$$

Ainsi,

$$\int_{\Omega} \mathbf{1}_A U \mathbb{E}[Y \mid \mathcal{G}] d\mathbb{P} = \int_{\Omega} \mathbf{1}_A UY d\mathbb{P},$$

c'est-à-dire

$$\int_A U \mathbb{E}[Y \mid \mathcal{G}] d\mathbb{P} = \int_A UY d\mathbb{P}.$$

La variable $U \mathbb{E}[Y \mid \mathcal{G}]$ est donc $\mathcal{G}$ -mesurable et satisfait

$$\int_A U \mathbb{E}[Y \mid \mathcal{G}] d\mathbb{P} = \int_A UY d\mathbb{P}.$$

Par unicité de l'espérance conditionnelle, on conclut que

$$\mathbb{E}[UY \mid \mathcal{G}] = U \mathbb{E}[Y \mid \mathcal{G}].$$

□

Dans la suite de ce document, lorsqu'une espérance conditionnelle est prise par rapport à la tribu engendrée par une variable aléatoire X (notée $\sigma(X)$), on notera plus simplement $\mathbb{E}[\cdot \mid X]$ conformément aux notations usuelles de la littérature. De plus, on utilisera la notation $\mathbb{E}[\cdot \mid X = x]$ lorsqu'il s'agira d'évaluer cette espérance pour une réalisation donnée x .

3 Mise en contexte

Notre jeu de données consiste en un ensemble d'images i.i.d $\{x_0^{(i)} \in \mathbb{R}^d\}$, suivant une loi de probabilité inconnue $\mathbb{P}_{\text{data}}$ où d correspond au nombre de pixels de chaque image multiplié par 3 dans le cas d'images couleur à trois canaux (RGB). Par exemple, pour des images de taille 32×32 , on a $d = 32 \times 32 \times 3$. Nous supposons que la distribution des données $\mathbb{P}_{\text{data}}$ est absolument continue par rapport à la mesure de Lebesgue sur $\mathbb{R}^d$ et admet un moment d'ordre 2. Elle admet donc une densité, que l'on note p_{data} . La densité p_{data} décrit alors la répartition des images dans $\mathbb{R}^d$, c'est-à-dire la probabilité relative d'observer les différentes régions de l'espace des images. Dans la suite du document, chaque image est représentée par un vecteur de dimension d , dont les composantes correspondent aux intensités des différents canaux de couleur des pixels. De plus, lorsque aucune ambiguïté n'est possible, nous noterons simplement x_0 au lieu de $x_0^{(i)}$ pour désigner une image quelconque. Pour toute image x_0 , la quantité $p_{\text{data}}(x_0)$ mesure alors la densité de probabilité associée à cette image. Bien que $\mathbb{P}_{\text{data}}$ soit inconnue, nous disposons d'échantillons issus de celle-ci : les images du jeu de données.

4 Schéma à suivre

L'objectif de la génération d'images est de produire de nouvelles images, notées $\hat{x}_1$, suivant la distribution $\mathbb{P}_{\text{data}}$. Pour cela, on part d'images, notées $\hat{x}_0$, suivant une distribution simple, choisie dans ce mémoire comme une loi normale

$$\hat{x}_0 \sim \mathcal{N}(0, \lambda \cdot I),$$

où $\lambda \in \mathbb{R}_+$.

La génération d'images consiste alors à construire un processus de génération permettant de transformer une image $\hat{x}_0 \sim \mathcal{N}(0, \lambda \cdot I)$ en une image $\hat{x}_1 \sim \mathbb{P}_{\text{data}}$.

La distribution $\mathbb{P}_{\text{data}}$ étant inconnue, ce processus de génération ne peut pas être construit directement. On dispose cependant d'un ensemble fini d'images d'entraînement x_0 issues de cette distribution. Ces images sont alors utilisées afin d'entraîner le modèle à construire un processus de génération $(\hat{x}_t)_{t \in [0,1]}$ capable de produire de nouvelles images suivant $\mathbb{P}_{\text{data}}$. Dans la suite du document, on considérera donc

$$x_0 \sim \mathbb{P}_{\text{data}}, \quad \hat{x}_1 \sim \mathbb{P}_{\text{data}}, \quad t \sim \mathcal{U}([0, 1]).$$

Afin d'alléger les notations, ces distributions seront désormais sous-entendues et ne seront plus précisées systématiquement.

La génération d'images comporte donc deux étapes distinctes : une phase d'entraînement, utilisant les images du jeu de données x_0 , puis une phase de génération consistant à produire de nouvelles images $\hat{x}_1$ suivant la distribution $\mathbb{P}_{\text{data}}$. Deux familles de modèles génératifs seront alors présentées dans ce document.

5 Modèles de Diffusion

Les modèles de diffusion sont une famille de modèles génératifs dont le principe consiste à obtenir un processus direct $(x_t)_{t \in [0,1]}$ correspondant à un ajout progressif de bruit aux images du jeu de données x_0 jusqu'à obtenir des images x_1 suivant une distribution proche de la loi normale $\mathcal{N}(0, \lambda \cdot I)$. Une fois ce processus de bruitage fixé, il est possible de générer de nouvelles images $\hat{x}_1$ en effectuant le processus inverse sur des images $\hat{x}_0 \sim \mathcal{N}(0, \lambda \cdot I)$.

Le processus de génération $(\hat{x}_t)_{t \in [0,1]}$ est donc le processus de débruitage tel que pour tout $t \in [0, 1]$:

$$\mathcal{L}(\hat{x}_t) = \mathcal{L}(x_{1-t}).$$

5.1 Score-based Generative Models

5.1.1 Définitions

Le modèle **Score-based Generative Models (SGM)** est caractérisé par l'utilisation d'une équation différentielle stochastique (EDS) pour la génération. Nous avons donc besoin de définir ce qu'est une EDS. Pour cela on a besoin au préalable de la notion d'espace probabilisé filtré, qui formalise l'idée d'une information croissante au cours du temps.

Définition 5.1 (Espace probabilisé filtré). *Un espace probabilisé filtré est un quadruplet $(\Omega, \mathcal{F}, (\mathcal{F}_t)_{t \geq 0}, \mathbb{P})$ où :*

- $(\Omega, \mathcal{F}, \mathbb{P})$ est un espace probabilisé ;
- $(\mathcal{F}_t)_{t \geq 0}$ est une famille croissante de sous-tribus de $\mathcal{F}$, appelée filtration, c'est-à-dire que

$$\mathcal{F}_s \subseteq \mathcal{F}_t, \quad \forall 0 \leq s \leq t.$$

Définition 5.2 (Processus stochastique réel / Processus stochastique vectoriel réel). *Soit $(\Omega, \mathcal{F}, (\mathcal{F}_t)_{t \geq 0}, \mathbb{P})$ un espace probabilisé filtré. Un processus stochastique réel $(X_t)_{t \geq 0}$ est une famille de variables aléatoires $X_t : (\Omega, \mathcal{F}) \rightarrow (\mathbb{R}, \mathcal{B}(\mathbb{R}))$, c'est-à-dire telle que, pour tout $t \geq 0$, X_t est $\mathcal{F}_t$ -mesurable.*

Un processus stochastique vectoriel réel (de dimension d) est une famille de variables aléatoires

$$(\tilde{X}_t)_{t \geq 0}, \quad \tilde{X}_t : (\Omega, \mathcal{F}) \rightarrow (\mathbb{R}^d, \mathcal{B}(\mathbb{R}^d)),$$

telle que, pour tout $t \geq 0$, le vecteur aléatoire $\tilde{X}_t$ peut s'écrire sous la forme

$$\tilde{X}_t = \begin{pmatrix} (X_t)_1 \\ (X_t)_2 \\ \vdots \\ (X_t)_d \end{pmatrix},$$

où $\forall i \in [1, d]$, chacune des composantes $((X_t)_i)_{t \geq 0}$, est un processus stochastique réel.

Dans la suite de ce mémoire, conformément aux conventions usuelles, la précision « réel » sera omise. De plus, la suite du document ne traitant que de processus stochastiques vectoriels, on appellera simplement processus stochastique un processus stochastique vectoriel et l'on notera simplement X_t plutôt que $\tilde{X}_t$.

Définition 5.3 (Processus stochastique adapté). Soit $(\Omega, \mathcal{F}, (\mathcal{F}_t)_{t \geq 0}, \mathbb{P})$ un espace probabilisé filtré. Un processus stochastique $(X_t)_{t \geq 0}$ est dit adapté à la filtration $(\mathcal{F}_t)_{t \geq 0}$ si $\forall t \geq 0, X_t$ est $\mathcal{F}_t$ -mesurable. Autrement dit, la valeur de X_t est entièrement déterminée par l'information disponible au temps t .

Définition 5.4 (Mouvement brownien standard). Soit $(\Omega, \mathcal{F}, (\mathcal{F}_t)_{t \geq 0}, \mathbb{P})$ un espace probabilisé filtré. Un processus stochastique vectoriel de dimension d ,

$$(B_t)_{t \geq 0},$$

est appelé mouvement brownien standard (de dimension d) par rapport à la filtration $(\mathcal{F}_t)_{t \geq 0}$, s'il vérifie :

1. $B_0 = 0$ $\mathbb{P}$ -presque sûrement sur Ω ;
2. $(B_t)_{t \geq 0}$ est adapté à la filtration $(\mathcal{F}_t)_{t \geq 0}$;
3. pour tous $0 \leq s < t$, l'accroissement

$$B_t - B_s$$

est indépendant de $\mathcal{F}_s$;

4. pour tous $0 \leq s < t$,

$$B_t - B_s \sim \mathcal{N}(0, (t - s)I_d),$$

où I_d désigne la matrice identité de $\mathbb{R}^d$;

5. presque sûrement, la trajectoire

$$t \longmapsto B_t(\omega)$$

est continue sur $[0, +\infty[$.

Pour la suite de ce document, on fixe un réel $T > 0$. Sauf indication contraire, tous les processus stochastiques sont considérés sur l'intervalle de temps $[0, T]$.

Lemme 5.5 (Intégrale stochastique pour les processus étagés). Soit $(B_t)_{t \in [0, T]}$ un mouvement brownien standard de dimension d .

Soit $n \in \mathbb{N}^*$ et

$$0 = t_0 < t_1 < \dots < t_n = T,$$

une subdivision de $[0, T]$.

Soit $(H_t)_{t \in [0, T]}$ un processus étagé de la forme

$$H_t = \sum_{k=0}^{n-1} H_k \mathbf{1}_{[t_k, t_{k+1}]}(t),$$

où, pour tout $k \in \llbracket 0, n-1 \rrbracket$, H_k est une variable aléatoire $\mathcal{F}_{t_k}$ -mesurable à valeurs dans $\mathbb{R}^d$ telle que

$$\mathbb{E}[\|H_k\|^2] < +\infty.$$

On définit alors l'intégrale stochastique de H par rapport au mouvement brownien standard $(B_t)_{t \in [0, T]}$ par

$$\int_0^T H_t^\top dB_t := \sum_{k=0}^{n-1} H_k^\top (B_{t_{k+1}} - B_{t_k}).$$

Cette intégrale est une variable aléatoire réelle et vérifie l'isométrie d'Itô :

$$\mathbb{E} \left[\left(\int_0^T H_t^\top dB_t \right)^2 \right] = \mathbb{E} \left[\int_0^T \|H_t\|^2 dt \right].$$

Démonstration. Par définition,

$$\int_0^T H_t^\top dB_t = \sum_{k=0}^{n-1} H_k^\top (B_{t_{k+1}} - B_{t_k}).$$

En développant le carré, on obtient

$$\begin{aligned} & \mathbb{E} \left[\left(\int_0^T H_t^\top dB_t \right)^2 \right] \\ &= \sum_{k=0}^{n-1} \mathbb{E} \left[(H_k^\top (B_{t_{k+1}} - B_{t_k}))^2 \right] \\ & \quad + 2 \sum_{0 \leq i < j \leq n-1} \mathbb{E} [H_i^\top (B_{t_{i+1}} - B_{t_i}) H_j^\top (B_{t_{j+1}} - B_{t_j})]. \end{aligned}$$

Montrons que les termes croisés sont nuls.

Soit $(i, j) \in \llbracket 0, n-1 \rrbracket^2$, avec $i < j$,

En utilisant (i) de la propriété 2.7 :

$$\mathbb{E} [H_i^\top (B_{t_{i+1}} - B_{t_i}) H_j^\top (B_{t_{j+1}} - B_{t_j})] = \mathbb{E} [E [H_i^\top (B_{t_{i+1}} - B_{t_i}) H_j^\top (B_{t_{j+1}} - B_{t_j}) \mid \mathcal{F}_{t_j}]]$$

De plus, comme

$$H_i^\top (B_{t_{i+1}} - B_{t_i}) H_j^\top$$

est $\mathcal{F}_{t_j}$ -mesurable, on obtient d'après (iii) de la propriété 2.7 :

$$\mathbb{E} [E [H_i^\top (B_{t_{i+1}} - B_{t_i}) H_j^\top (B_{t_{j+1}} - B_{t_j}) \mid \mathcal{F}_{t_j}]] = \mathbb{E} [H_i^\top (B_{t_{i+1}} - B_{t_i}) H_j^\top \mathbb{E} [B_{t_{j+1}} - B_{t_j} \mid \mathcal{F}_{t_j}]].$$

Comme l'accroissement

$$B_{t_{j+1}} - B_{t_j}$$

est par définition indépendant de la tribu $\mathcal{F}_{t_j}$, on a alors,

$$\mathbb{E} [B_{t_{j+1}} - B_{t_j} \mid \mathcal{F}_{t_j}] = \mathbb{E} [B_{t_{j+1}} - B_{t_j}].$$

Or,

$$\mathbb{E} [B_{t_{j+1}} - B_{t_j}] = 0$$

donc

$$\mathbb{E} [B_{t_{j+1}} - B_{t_j} \mid \mathcal{F}_{t_j}] = 0.$$

Ainsi,

$$\mathbb{E} [H_i^\top (B_{t_{i+1}} - B_{t_i}) H_j^\top (B_{t_{j+1}} - B_{t_j})] = 0.$$

Par conséquent, les termes croisés sont nuls et,

$$\mathbb{E} \left[\left(\int_0^T H_t^\top dB_t \right)^2 \right] = \sum_{k=0}^{n-1} \mathbb{E} \left[(H_k^\top (B_{t_{k+1}} - B_{t_k}))^2 \right].$$

Comme H_k est $\mathcal{F}_{t_k}$ -mesurable et que

$$B_{t_{k+1}} - B_{t_k} \sim \mathcal{N}(0, (t_{k+1} - t_k)I_d),$$

on a

$$\mathbb{E}[(B_{t_{k+1}} - B_{t_k})(B_{t_{k+1}} - B_{t_k})^\top] = (t_{k+1} - t_k)I_d.$$

Par conséquent,

$$\begin{aligned}\mathbb{E}\left[(H_k^\top (B_{t_{k+1}} - B_{t_k}))^2\right] &= \mathbb{E}[H_k^\top (t_{k+1} - t_k)I_d H_k] \\ &= (t_{k+1} - t_k)\mathbb{E}[\|H_k\|^2].\end{aligned}$$

Ainsi,

$$\mathbb{E}\left[\left(\int_0^T H_t^\top dB_t\right)^2\right] = \sum_{k=0}^{n-1} (t_{k+1} - t_k)\mathbb{E}[\|H_k\|^2].$$

Enfin,

$$\int_0^T \|H_t\|^2 dt = \sum_{k=0}^{n-1} (t_{k+1} - t_k)\|H_k\|^2.$$

En prenant l'espérance,

$$\mathbb{E}\left[\int_0^T \|H_t\|^2 dt\right] = \sum_{k=0}^{n-1} (t_{k+1} - t_k)\mathbb{E}[\|H_k\|^2].$$

On en déduit donc,

$$\mathbb{E}\left[\left(\int_0^T H_t^\top dB_t\right)^2\right] = \mathbb{E}\left[\int_0^T \|H_t\|^2 dt\right].$$

□

On admettra par la suite que, par un argument de densité propre aux processus stochastiques, cette construction s'étend de manière unique à tout l'espace $L_{\text{ad}}^2([0, T] \times \Omega; \mathbb{R}^d)$ où

$$L_{\text{ad}}^2([0, T] \times \Omega; \mathbb{R}^d) = \left\{ (H_t)_{t \in [0, T]} \left| (H_t)_{t \in [0, T]} \text{ est adapté et } \mathbb{E}\left[\int_0^T \|H_t\|^2 dt\right] < +\infty \right. \right\}.$$

On peut maintenant donner la définition d'équation différentielle stochastique :

Définition 5.6 (Équation différentielle stochastique). *Soit $(\Omega, \mathcal{F}, (\mathcal{F}_t)_{t \in [0, T]}, \mathbb{P})$ un espace probabilisé filtré et soit $(B_t)_{t \in [0, T]}$ un mouvement brownien standard adapté à la filtration $(\mathcal{F}_t)_{t \in [0, T]}$.*

On appelle équation différentielle stochastique l'équation intégrale :

$$X_t = X_0 + \int_0^t f(X_s, s) ds + \int_0^t g(X_s, s) dB_s, \quad t \in [0, T],$$

où

$$f : [0, T] \times \mathbb{R}^d \rightarrow \mathbb{R}^d, \quad g : [0, T] \times \mathbb{R}^d \rightarrow \mathbb{R}^{d \times d}$$

sont deux fonctions régulières telles que le processus $(g(X_t, t))_{t \in [0, T]}$ soit adapté et vérifie

$$\mathbb{E}\left[\int_0^T \|g(X_t, t)\|^2 dt\right] < +\infty.$$

L'EDS s'écrit formellement sous la forme différentielle

$$dX_t = f(X_t, t) dt + g(X_t, t) dB_t, \quad X_0 = x_0.$$

On peut maintenant chercher à obtenir le processus de génération.

5.1.2 Obtention du processus de génération

L'objectif est maintenant d'obtenir le processus de génération $(\hat{x}_t)_{t \in [0,1]}$. Pour cela, il faut au préalable fixer le processus de bruitage $(x_t)_{t \in [0,1]}$. On commence donc par établir une EDS modélisant l'ajout progressif d'un bruit de variance $\sigma^2(t)$ à une image, où $\sigma : [0, 1] \rightarrow \mathbb{R}_+$ est une fonction croissante, de classe $\mathcal{C}^1$ vérifiant $\sigma(0) = 0$. Cette construction s'applique à toute image; toutefois, afin d'éviter d'introduire de nouvelles notations, nous considérons directement le bruitage des images x_0 du jeu de données. On souhaite donc que, conditionnellement à x_0 , pour tout $t \in [0, 1]$, l'image bruitée x_t suive une loi normale centrée en x_0 et de variance $\sigma^2(t)$, c'est-à-dire,

$$x_t \mid x_0 \sim \mathcal{N}(x_0, \sigma^2(t) \cdot I).$$

Dans toute la suite de cette section, on suppose que $\sigma : [0, 1] \rightarrow \mathbb{R}_+$ est une fonction croissante, de classe $\mathcal{C}^1$ vérifiant $\sigma(0) = 0$. Le théorème suivant montre alors qu'un tel processus de bruitage existe et donne explicitement l'EDS qu'il vérifie.

Théorème 5.7. *Soit $(B_t)_{t \in [0,1]}$ un mouvement brownien standard et soit X_0 une variable aléatoire indépendante de $(B_t)_{t \in [0,1]}$. Alors le processus stochastique $(X_t)_{t \in [0,1]}$ défini par*

$$X_t = X_0 + \int_0^t \sqrt{\frac{d[\sigma^2(s)]}{ds}} dB_s$$

est bien défini, solution de l'équation différentielle stochastique

$$dX_t = \sqrt{\frac{d[\sigma^2(t)]}{dt}} dB_t,$$

et vérifie de plus

$$X_t \mid X_0 \sim \mathcal{N}(X_0, \sigma^2(t) \cdot I).$$

Démonstration. Posons

$$g(t) = \sqrt{\frac{d[\sigma^2(t)]}{dt}}.$$

Pour simplifier la démonstration, on suppose dans un premier temps que g est constante par morceaux. Soit $n \in \mathbb{N}^*$, il existe donc une subdivision

$$0 = t_0 < t_1 < \dots < t_n = 1$$

et des constantes $a_0, \dots, a_{n-1} \geq 0$ telles que

$$g(t) = a_k, \quad t \in [t_k, t_{k+1}[.$$

Le processus

$$X_t = X_0 + \int_0^t g(s) dB_s$$

est alors bien défini puisque g est un processus étagé déterministe. D'après la définition de l'intégrale stochastique,

$$\int_0^t g(s) dB_s = \sum_{k=0}^{m-1} a_k (B_{t_{k+1}} - B_{t_k}) + a_m (B_t - B_{t_m}),$$

où pour tout $t \in [0, 1]$, il existe un unique $m \in \llbracket 0, n-1 \rrbracket$ tel que $t \in [t_m, t_{m+1}[$.

Cette intégrale est donc une combinaison linéaire finie d'accroissements browniens indépendants.

Or chacun des accroissements vérifie

$$B_{t_{k+1}} - B_{t_k} \sim \mathcal{N}(0, (t_{k+1} - t_k) \cdot I),$$

et ils sont indépendants. Par conséquent,

$$\int_0^t g(s) dB_s$$

est une variable gaussienne centrée.

Sa variance vaut

$$\sum_{k=0}^{m-1} a_k^2(t_{k+1} - t_k) + a_m^2(t - t_m),$$

c'est-à-dire

$$\int_0^t g(s)^2 ds.$$

De plus, comme

$$g(s)^2 = \frac{d\sigma^2(s)}{ds},$$

on obtient

$$\int_0^t g(s)^2 ds = \int_0^t \frac{d\sigma^2(s)}{ds} ds = \sigma^2(t) - \sigma^2(0) = \sigma^2(t),$$

puisque $\sigma(0) = 0$.

Ainsi,

$$\int_0^t g(s) dB_s \sim \mathcal{N}(0, \sigma^2(t) \cdot I). \quad (1)$$

Comme

$$X_t = X_0 + \int_0^t g(s) dB_s$$

et que X_0 est indépendant du mouvement brownien, on en déduit

$$(X_t - X_0) \mid X_0 \sim \mathcal{N}(0, \sigma^2(t) \cdot I),$$

c'est-à-dire

$$X_t \mid X_0 \sim \mathcal{N}(X_0, \sigma^2(t) \cdot I).$$

Enfin, l'équation intégrale

$$X_t = X_0 + \int_0^t g(s) dB_s$$

est précisément la forme intégrale de l'équation différentielle stochastique

$$dX_t = g(t) dB_t = \sqrt{\frac{d[\sigma^2(t)]}{dt}} dB_t.$$

On a donc démontré le résultat lorsque g est constante par morceaux.

Dans le cas général où g est continue, on peut approcher uniformément g par une suite de fonctions constantes par morceaux. Les intégrales stochastiques correspondantes convergent alors vers

$$\int_0^t g(s) dB_s,$$

de sorte que le résultat précédent se prolonge par passage à la limite. On admettra le cas général dans la suite de ce document. $\square$

Ainsi, l'EDS décrivant un bruitage est :

$$dx_t = \sqrt{\frac{d[\sigma^2(t)]}{dt}} dB_t \quad (2)$$

Ainsi, en intégrant (2) entre $t=0$ et $t=1$:

$$x_1 = x_0 + \int_0^1 \sqrt{\frac{d[\sigma^2(t)]}{dt}} dB_t \quad (3)$$

Ainsi, en utilisant (3), on peut bruite les images x_0 du jeu de données pour obtenir des images $x_1 \sim \mathcal{N}(0, \sigma^2(1) \cdot I)$. Cependant, bruite avec (3) n'est pas la manière optimale pour bruite des images puisque nécessitant l'algorithme d'Euler-Maruyama.

Toutefois, puisque $(B_t)_{t \in [0,1]}$ est un mouvement brownien standard, d'après (1),

$$\int_0^1 \sqrt{\frac{d[\sigma^2(t)]}{dt}} dB_t \sim \mathcal{N}(0, \sigma^2(1) \cdot I)$$

Et

$$\sigma(1) \cdot Z \sim \mathcal{N}(0, \sigma^2(1) \cdot I)$$

où $Z \sim \mathcal{N}(0, I)$.

Donc

$$\int_0^1 \sqrt{\frac{d[\sigma^2(t)]}{dt}} dB_t \stackrel{\mathcal{L}}{=} \sigma(1) \cdot Z \quad (4)$$

Par conséquent, d'après (3),

$$x_1 = x_0 + \sigma(1) \cdot Z. \quad (5)$$

Ainsi, (5) permet maintenant de bruite des images uniquement en évaluant σ ce qui est nettement moins coûteux que l'algorithme d'Euler-Maruyama.

Maintenant que l'on a le processus $(x_t)_{t \in [0,1]}$ et l'EDS permettant de bruite des images, on peut obtenir l'EDS permettant de débruite des images et le processus de génération $(\hat{x}_t)_{t \in [0,1]}$. Pour cela on a besoin de définir la densité marginale d'un processus stochastique :

Définition 5.8 (Densité marginale). *Soit $(X_t)_{t \in [0,T]}$ un processus stochastique.*

Pour tout instant $t \in [0, T]$, la loi de la variable aléatoire X_t est appelée la distribution marginale du processus au temps t .

Lorsque cette loi est absolument continue par rapport à la mesure de Lebesgue sur $\mathbb{R}^d$, elle admet une densité, notée p_t , telle que

$$\mathbb{P}(X_t \in A) = \int_A p_t(x) dx, \quad \forall A \in \mathcal{B}(\mathbb{R}^d),$$

où $\mathcal{B}(\mathbb{R}^d)$ désigne la tribu borélienne de $\mathbb{R}^d$. La fonction $x \mapsto p_t(x)$ est appelée la densité marginale du processus au temps t .

Dans la suite du document, on suppose que, pour presque tout $x \in \mathbb{R}^d$, l'application

$$t \mapsto p_t(x)$$

est $\mathcal{C}^\infty$. On suppose également que dans la suite de cette section, pour tout $t \in]0, 1]$, l'image bruitée x_t admet une densité marginale p_t strictement positive sur $\mathbb{R}^d$.

On peut alors obtenir l'EDS liée au processus de débruitage grâce au théorème suivant.

Théorème 5.9 (Théorème d'inversion d'Anderson). Soit $(X_t)_{t \in [0, T]}$ la solution de l'équation différentielle stochastique

$$dX_t = f(X_t, t) dt + g(t) dB_t,$$

où $(B_t)_{t \in [0, T]}$ est un mouvement brownien standard, $f : \mathbb{R}^d \times [0, T] \rightarrow \mathbb{R}^d$ et $g : [0, T] \rightarrow \mathbb{R}$ sont deux fonctions régulières.

On suppose que, pour tout $t \in [0, T]$, la variable aléatoire X_t admet une densité marginale p_t .

Alors le processus inversé en temps $(\hat{X}_t)_{t \in [0, T]}$ satisfait l'équation inverse

$$d\hat{X}_t = \left[-f(\hat{X}_t, T-t) + g(T-t)^2 \nabla_X \log p_{T-t}(\hat{X}_t) \right] dt + g(T-t) d\bar{B}_t,$$

où $(\bar{B}_t)_{t \in [0, T]}$ est un mouvement brownien standard obtenu par renversement du temps du mouvement brownien standard $(B_t)_{t \in [0, T]}$.

Démonstration. Démonstration admise. □

Corollaire 5.10. Soit $(X_t)_{t \in [0, 1]}$ un processus stochastique vérifiant,

$$X_t \mid X_0 \sim \mathcal{N}(X_0, \sigma^2(t) \cdot I),$$

Alors le processus inversé en temps $(\hat{X}_t)_{t \in [0, 1]}$ satisfait l'équation inverse

$$d\hat{X}_t = \frac{d[\sigma^2(u)]}{du} \Big|_{u=1-t} \nabla_X \log p_{1-t}(\hat{X}_t) dt + \sqrt{\frac{d[\sigma^2(u)]}{du} \Big|_{u=1-t}} d\bar{B}_t,$$

où $(\bar{B}_t)_{t \in [0, 1]}$ est un mouvement brownien standard.

Démonstration. On applique juste le théorème d'inversion d'Anderson avec $T=1$, $f(x, t) = 0$ et $g(t) = \sqrt{\frac{d[\sigma^2(t)]}{dt}}$. □

Par conséquent, l'EDS caractérisant le débruitage d'une image est :

$$d\hat{x}_t = \frac{d[\sigma^2(u)]}{du} \Big|_{u=1-t} \nabla_x \log p_{1-t}(\hat{x}_t) dt + \sqrt{\frac{d[\sigma^2(u)]}{du} \Big|_{u=1-t}} d\bar{B}_t. \quad (6)$$

Ainsi, en intégrant entre $t = 0$ et $t = 1$ l'équation (6),

$$\hat{x}_1 = \hat{x}_0 + \int_0^1 \frac{d[\sigma^2(u)]}{du} \Big|_{u=1-t} \nabla_x \log p_{1-t}(\hat{x}_t) dt + \int_0^1 \sqrt{\frac{d[\sigma^2(u)]}{du} \Big|_{u=1-t}} d\bar{B}_t,$$

soit en effectuant le changement de variable $t \mapsto 1-t$:

$$\hat{x}_1 = \hat{x}_0 + \int_0^1 \frac{d[\sigma^2(t)]}{dt} \nabla_x \log p_t(\hat{x}_{1-t}) dt + \int_0^1 \sqrt{\frac{d[\sigma^2(t)]}{dt}} dB_t.$$

Pour le mouvement brownien standard, ce changement de variable est ici considéré formellement, sans justification rigoureuse.

Enfin, d'après (4), on obtient :

$$\hat{x}_1 = \hat{x}_0 + \int_0^1 \frac{d[\sigma^2(t)]}{dt} \nabla_x \log p_t(\hat{x}_{1-t}) dt + \sigma(1) \cdot Z. \quad (7)$$

On pourrait alors penser que l'on peut générer des images $\hat{x}_1$ suivant la distribution $\mathbb{P}_{\text{data}}$ grâce à des images bruitées $\hat{x}_0$ et (7). Cependant, on remarque que (7) dépend de la densité marginale $p_t(\hat{x}_{1-t})$. Or, $p_t(\hat{x}_{1-t})$ dépend de p_{data} , qui est quasi-impossible à obtenir. Cependant, (7) ne dépend pas directement de $p_t(\hat{x}_{1-t})$ mais de $\nabla_x \log p_t(\hat{x}_{1-t})$. L'idée est alors d'approximer $\nabla_x \log p_t(\hat{x}_{1-t})$ sans utiliser $p_t(\hat{x}_{1-t})$. Pour cela on entraîne un réseau neuronal à approximer $\nabla_x \log p_t$.

5.1.3 Entraînement

On appelle **score** le gradient de la log-densité, c'est-à-dire la quantité $\nabla_x \log p_t(x)$. Pour estimer le score, on introduit un réseau de neurones de paramètres θ , appelé **score network** et noté $s_\theta : \mathbb{R}^d \times [0, 1] \rightarrow \mathbb{R}^d$. La difficulté principale réside dans le fait que le calcul exact du score $\nabla_x \log p_t(\hat{x}_{1-t})$ est impossible en pratique : il dépend de la densité marginale p_t , qui elle-même découle de la distribution inconnue $\mathbb{P}_{\text{data}}$. Pour contourner ce problème et entraîner le réseau s_θ , la seule ressource dont nous disposons est notre jeu d'images empiriques x_0 . La stratégie d'entraînement repose sur l'idée suivante : nous allons volontairement bruite nos images réelles x_0 pour générer des images x_1 telles que $x_1 | x_0 \sim \mathcal{N}(x_0, \sigma^2(1) \cdot I)$. L'objectif du réseau s_θ sera d'apprendre à inverser ce processus, c'est-à-dire à débruiter ces images pour retrouver des images suivant la distribution $\mathbb{P}_{\text{data}}$.

Dès lors, nous pouvons formaliser l'objectif d'entraînement du score network s_θ . Idéalement, nous souhaitons que $s_\theta(x_t, t)$ coïncide avec le véritable score $\nabla_x \log p_t(x_t)$ pour tout temps t . Cela se traduit par la minimisation de l'erreur quadratique moyenne suivante :

$$\frac{1}{2} \mathbb{E}_{x_0} \mathbb{E}_t \mathbb{E}_{x_t \sim \mathcal{N}(x_0, \sigma^2(t) \cdot I)} [\|s_\theta(x_t, t) - \nabla_x \log p_t(x_t)\|_2^2] \quad (8)$$

L'optimisation de ce terme est l'étape clé du modèle SGM. En effet, une fois le réseau entraîné, il suffit de substituer le score théorique inconnu par notre approximation $s_\theta(x_t, t)$ dans (7). On peut alors générer de nouvelles images $\hat{x}_1$ à partir d'un bruit initial $\hat{x}_0$ et de (7). En pratique, minimiser directement l'équation (8) est impossible car $p_t(x_t)$ est inobtenable. En revanche, la densité conditionnelle $p_t(x_t | x_0)$ issue du processus de bruitage est parfaitement connue et explicite. L'enjeu est donc de reformuler cet objectif inaccessible afin de faire apparaître ce terme conditionnel. Ce passage crucial repose sur le théorème suivant :

Théorème 5.11. *[Denoising Score Matching] On note*

$$E(\theta) = \frac{1}{2} \mathbb{E}_{X_0 \sim \mathbb{P}_{\text{data}}} \mathbb{E}_t \mathbb{E}_{X_t \sim \mathcal{N}(X_0, \sigma^2(t) \cdot I)} [\|s_\theta(X_t, t) - \nabla_X \log p_t(X_t)\|_2^2]$$

Alors :

$$E(\theta) = \frac{1}{2} \mathbb{E}_{X_0 \sim \mathbb{P}_{\text{data}}} \mathbb{E}_t \mathbb{E}_{X_t \sim \mathcal{N}(X_0, \sigma^2(t) \cdot I)} \left[\left\| s_\theta(X_t, t) + \frac{X_t - X_0}{\sigma^2(t)} \right\|_2^2 \right] + C,$$

où C ne dépend pas de θ .

5.1.4 Démonstration du Denoising Score Matching

Pour démontrer le théorème, on a d'abord besoin des lemmes suivants.

Lemme 5.12. *Soit $(X)_{t \in [0,1]}$ un processus stochastique et $X_0 \mapsto \nabla_X \log p_t(X | X_0) p_t(X_0 | X) \in L^1(\mathbb{R}^d)$*

Alors

$$\nabla_X \log p_t(X_t) = \mathbb{E}[\nabla_X \log p_t(X_t | X_0) | X_t].$$

Démonstration. On a :

$$p_t(X_t) = \int_{\mathbb{R}^d} p_t(X_t | X_0) p_{\text{data}}(X_0) dX_0$$

De plus, pour tout $t \in]0, 1]$ et pour tout $X_0 \in \mathbb{R}^d$, la fonction $X \mapsto p_t(X | X_0)$ est de classe C^1 et,

$$\begin{aligned} \nabla_X p_t(X | X_0) &= \nabla_X \left(\frac{1}{(2\pi\sigma^2(t))^{d/2}} \exp\left(-\frac{\|X - X_0\|_2^2}{2\sigma^2(t)}\right) \right) \\ &= \frac{1}{(2\pi\sigma^2(t))^{d/2}} \left(-\frac{X - X_0}{\sigma^2(t)} \right) \exp\left(-\frac{\|X - X_0\|_2^2}{2\sigma^2(t)}\right) = -\frac{X - X_0}{(2\pi)^{d/2} \sigma(t)^{d+2}} \exp\left(-\frac{\|X - X_0\|_2^2}{2\sigma^2(t)}\right) \end{aligned}$$

est intégrable par rapport à X_0 par croissance comparée. Ainsi d'après le théorème de dérivation pour les intégrales à paramètre, on a

$$\nabla_X p_t(X_t) = \int_{\mathbb{R}^d} \nabla_X p_t(X_t | X_0) p_{\text{data}}(X_0) dX_0$$

Comme

$$\nabla_X p_t(X_t | X_0) = \nabla_X \log p_t(X_t | X_0) p_t(X_t | X_0),$$

on obtient

$$\nabla_X p_t(X_t) = \int_{\mathbb{R}^d} \nabla_X \log p_t(X_t | X_0) p_t(X_t | X_0) p_{\text{data}}(X_0) dX_0.$$

D'autre part,

$$\nabla_X p_t(X_t) = \nabla_X \log p_t(X_t) p_t(X_t),$$

d'où

$$\nabla_X \log p_t(X_t) p_t(X_t) = \int_{\mathbb{R}^d} \nabla_X \log p_t(X_t | X_0) p_t(X_t | X_0) p_{\text{data}}(X_0) dX_0.$$

Ainsi,

$$\nabla_X \log p_t(X_t) = \int_{\mathbb{R}^d} \nabla_X \log p_t(X_t | X_0) \frac{p_t(X_t | X_0) p_{\text{data}}(X_0)}{p_t(X_t)} dX_0.$$

De plus d'après la formule de Bayes,

$$p_t(X_0 | X_t) = \frac{p_t(X_t | X_0) p_{\text{data}}(X_0)}{p_t(X_t)}.$$

Par conséquent,

$$\nabla_X \log p_t(X_t) = \int_{\mathbb{R}^d} \nabla_X \log p_t(X_t | X_0) p_t(X_0 | X_t) dX_0.$$

On reconnaît alors l'espérance conditionnelle $\mathbb{E}[\nabla_X \log p_t(X_t | X_0) | X_t]$ donc :

$$\nabla_X \log p_t(X_t) = \mathbb{E}[\nabla_X \log p_t(X_t | X_0) | X_t]$$

□

On a également le lemme :

Lemme 5.13.

$$\mathbb{E}_{X_0 \sim \mathbb{P}_{\text{data}}} \mathbb{E}_t \mathbb{E}_{X_t \sim \mathcal{N}(X_0, \sigma^2(t) \cdot I)} [(s_\theta(X_t, t) - \nabla_X \log p_t(X_t))^\top (\nabla_X \log p_t(X_t) - \nabla_X \log p_t(X_t | X_0))] = 0$$

Démonstration. Pour cette démonstration, pour simplifier, on note $\mathbb{E}[\cdot]$ au lieu de $\mathbb{E}_{X_0 \sim \mathbb{P}_{\text{data}}} \mathbb{E}_t \mathbb{E}_{X_t \sim \mathcal{N}(X_0, \sigma^2(t) \cdot I)}[\cdot]$.

De plus, on note :

$$h(X_t, X) = \nabla_X \log p_t(X_t | X) \quad k(X) = \nabla_X \log p_t(X).$$

En utilisant (i) de la propriété 2.7, on obtient :

$$\mathbb{E}[(s_\theta(X_t, t) - k(X_t))^\top (k(X_t) - h(X_t, X_0))] = \mathbb{E}[\mathbb{E}[(s_\theta(X_t, t) - k(X_t))^\top (k(X_t) - h(X_t, X_0)) | X_t]].$$

De plus, le terme $s_\theta(X_t, t) - k(X_t)$ étant $\sigma(X_t)$ -mesurable, on a d'après (iii) de la propriété 2.7 :

$$\mathbb{E}[\mathbb{E}[(s_\theta(X_t, t) - k(X_t))^\top (k(X_t) - h(X_t, X_0)) \mid X_t]] = \mathbb{E}[(s_\theta(X_t, t) - k(X_t))^\top \mathbb{E}[k(X_t) - h(X_t, X_0) \mid X_t]].$$

Or, par linéarité de l'espérance,

$$\mathbb{E}[k(X_t) - h(X_t, X_0) \mid X_t] = \mathbb{E}[k(X_t) \mid X_t] - \mathbb{E}[h(X_t, X_0) \mid X_t].$$

De plus, en utilisant (iii) de la propriété 2.7 avec $Y = 1_\Omega$, $\sigma(X_t)$ -mesurable et $U = k(X_t)$, on obtient

$$\mathbb{E}[k(X_t) \mid X_t] = k(X_t) \mathbf{1}_\Omega = k(X_t).$$

Ainsi, en remplaçant, on obtient :

$$\mathbb{E}[(s_\theta(X_t, t) - k(X_t))^\top (k(X_t) - h(X_t, X_0))] = \mathbb{E}[(s_\theta(X_t, t) - k(X_t))^\top (k(X_t) - \mathbb{E}[h(X_t, X_0) \mid X_t])].$$

Or, d'après le lemme 5.12,

$$k(X_t) = \mathbb{E}[h(X_t, X_0) \mid X_t].$$

Le terme entre parenthèses est donc nul presque sûrement, ce qui implique que l'espérance globale est nulle. □

Pour finir, on a besoin du lemme :

Lemme 5.14. *Soit $(X_t)_{t \in [0,1]}$ un processus stochastique vérifiant,*

$$X_t \mid X_0 \sim \mathcal{N}(X_0, \sigma^2(t) \cdot I),$$

Alors

$$\nabla_X \log p_t(X_t \mid X_0) = -\frac{X_t - X_0}{\sigma^2(t)}$$

Démonstration. On a :

$$p_t(X_t \mid X_0) = \frac{1}{(2\pi\sigma^2(t))^{d/2}} \exp\left(-\frac{\|X_t - X_0\|_2^2}{2\sigma^2(t)}\right).$$

Ainsi, on pose

$$f(X) = \frac{1}{(2\pi\sigma^2(t))^{d/2}} \exp\left(-\frac{\|X - X_0\|_2^2}{2\sigma^2(t)}\right)$$

En prenant le logarithme, on obtient

$$\log f(X) = -\frac{d}{2} \log(2\pi\sigma^2(t)) - \frac{\|X - X_0\|_2^2}{2\sigma^2(t)}.$$

On a alors :

$$\nabla_X \log f(X) = -\frac{1}{2\sigma^2(t)} \nabla_X \|X - X_0\|_2^2.$$

Or,

$$\nabla_X \|X - X_0\|_2^2 = 2(X - X_0).$$

Par conséquent,

$$\nabla_X \log f(X) = -\frac{1}{2\sigma^2(t)} 2(X - X_0) = -\frac{X - X_0}{\sigma^2(t)}.$$

Ainsi,

$$\nabla_X \log p_t(X_t \mid X_0) = \nabla_X \log f(X_t) = -\frac{X_t - X_0}{\sigma^2(t)}$$

□

On peut maintenant procéder à la démonstration du théorème.

Démonstration. Théorème 5.11

En utilisant les mêmes notations que dans le lemme 5.13 on a :

$$\begin{aligned}\|s_\theta(X_t, t) - h(X_t, X_0)\|_2^2 &= \|s_\theta(X_t, t) - k(X_t) + k(X_t) - h(X_t, X_0)\|_2^2 \\ &= \|s_\theta(X_t, t) - k(X_t)\|_2^2 \\ &\quad + 2(s_\theta(X_t, t) - k(X_t))^\top (k(X_t) - h(X_t, X_0)) \\ &\quad + \|k(X_t) - h(X_t, X_0)\|_2^2.\end{aligned}$$

En prenant l'espérance, il vient

$$\begin{aligned}\mathbb{E} [\|s_\theta(X_t, t) - h(X_t, X_0)\|_2^2] \\ &= \mathbb{E} [\|s_\theta(X_t, t) - k(X_t)\|_2^2] \\ &\quad + 2 \mathbb{E} [(s_\theta(X_t, t) - k(X_t))^\top (k(X_t) - h(X_t, X_0))] \\ &\quad + \mathbb{E} [\|k(X_t) - h(X_t, X_0)\|_2^2].\end{aligned}$$

Or d'après le lemme 5.13, le terme croisé est nul. Il reste donc

$$\mathbb{E} [\|s_\theta(X_t, t) - h(X_t, X_0)\|_2^2] = \mathbb{E} [\|s_\theta(X_t, t) - k(X_t)\|_2^2] + \mathbb{E} [\|k(X_t) - h(X_t, X_0)\|_2^2].$$

En multipliant par 1/2 et en transposant on obtient

$$\frac{1}{2} \mathbb{E} [\|s_\theta(X_t, t) - k(X_t)\|_2^2] = \frac{1}{2} \mathbb{E} [\|s_\theta(X_t, t) - h(X_t, X_0)\|_2^2] + C,$$

où $C = -\frac{1}{2} \mathbb{E} [\|h(X_t, X_0) - k(X_t)\|_2^2]$ ne dépend pas de θ .

En remplaçant $k(X_t)$ et $h(X_t, X_0)$ par leurs expressions respectives, et puisque la première expression ne dépend pas de X_0 , on obtient

$$E(\theta) = \frac{1}{2} \mathbb{E}_{X_0 \sim \mathbb{P}_{\text{data}}} \mathbb{E}_t \mathbb{E}_{X_t \sim \mathcal{N}(X_0, \sigma^2(t) \cdot I)} [\|s_\theta(X_t, t) - \nabla_X \log p_t(X_t | X_0)\|_2^2] + C.$$

De plus, d'après le lemme 5.14, $\nabla_X \log p_t(X_t | X_0) = -\frac{X_t - X_0}{\sigma^2(t)}$ donc :

$$E(\theta) = \frac{1}{2} \mathbb{E}_{X_0 \sim \mathbb{P}_{\text{data}}} \mathbb{E}_t \mathbb{E}_{X_t \sim \mathcal{N}(X_0, \sigma^2(t) \cdot I)} \left[\left\| s_\theta(X_t, t) + \frac{X_t - X_0}{\sigma^2(t)} \right\|_2^2 \right] + C.$$

□

Par conséquent, d'après le théorème 5.11, on a que (8) est égal à :

$$\frac{1}{2} \mathbb{E}_{x_0} \mathbb{E}_t \mathbb{E}_{x_t \sim \mathcal{N}(x_0, \sigma^2(t) \cdot I)} \left[\left\| s_\theta(x_t, t) + \frac{x_t - x_0}{\sigma^2(t)} \right\|_2^2 \right] + C. \quad (9)$$

On définit alors la mesure de l'erreur commise par le réseau neuronal pendant l'entraînement, notée $l(\theta)$, par $l(\theta) = \frac{1}{2} \mathbb{E}_{x_0} \mathbb{E}_t \mathbb{E}_{x_t \sim \mathcal{N}(x_0, \sigma^2(t) \cdot I)} [\|s_\theta(x_t, t) + \frac{x_t - x_0}{\sigma^2(t)}\|_2^2]$. Ainsi le terme à minimiser est d'après 9 :

$$l(\theta) + C.$$

De plus, puisque C ne dépend pas de θ , $\arg \min_\theta [l(\theta) + C] = \arg \min_\theta [l(\theta)]$.

Finalement, minimiser le terme :

$$\frac{1}{2} \mathbb{E}_{x_0} \mathbb{E}_t \mathbb{E}_{x_t \sim \mathcal{N}(x_0, \sigma^2(t) \cdot I)} [\|s_\theta(x_t, t) - \nabla_x \log p_t(x_t)\|_2^2]$$

est équivalent à minimiser le terme :

$$\frac{1}{2} \mathbb{E}_{x_0} \mathbb{E}_t \mathbb{E}_{x_t \sim \mathcal{N}(x_0, \sigma^2(t) \cdot I)} \left[\left\| s_\theta(x_t, t) + \frac{x_t - x_0}{\sigma^2(t)} \right\|_2^2 \right].$$

Ce qui d'après la loi des grands nombres, pour un ensemble de N images $\{x_0^{(1)}, \dots, x_0^{(N)}\} \subset \mathbb{R}^d$ suffisamment grand, correspond à minimiser :

$$\frac{1}{2N} \sum_{i=1}^N \left\| s_\theta(t^{(i)}, x_t^{(i)}) + \frac{x_t^{(i)} - x_0^{(i)}}{\sigma^2(t^{(i)})} \right\|_2^2.$$

L'expression obtenue ne dépend pas de p_{data} , seulement des images initiales x_0 . On peut donc dorénavant entraîner le score network s_θ à approximer le score $\nabla_x \log p_t$, pour cela, on utilise un algorithme de descente de gradient. Le seul terme de (7) qu'il reste à déterminer est donc le bruit $\sigma(t)$.

Pour déterminer le bruit $\sigma(t)$, on commence par déterminer les extrêmes $\sigma(0)$ et $\sigma(1)$.

5.1.5 Détermination de $\sigma(1)$

Pour générer de nouvelles images via l'EDS inverse, il est nécessaire d'échantillonner en utilisant des images x_1 obtenues grâce au processus de bruitage et dont la densité est

$$p_1(x_1) = \int_{\mathbb{R}^d} p_1(x_1 | x_0) p_{\text{data}}(x_0) dx_0.$$

Or, la distribution $\mathbb{P}_{\text{data}}$ étant inconnue, nous ne pouvons pas échantillonner directement selon p_1 . L'objectif est donc de choisir un niveau de bruit final $\sigma(1)$ suffisamment grand pour que la distribution associée à la densité marginale p_1 soit indiscernable de la distribution de référence $\mathcal{N}(0, \sigma^2(1) \cdot I)$ facile à échantillonner.

Pour formaliser cette idée, supposons que notre jeu de données est un ensemble fini de N images $\{x_0^{(1)}, \dots, x_0^{(N)}\}$. La distribution empirique est $\frac{1}{N} \sum_{i=1}^N \delta_{x_0^{(i)}}$, ce qui donne pour densité marginale empirique :

$$p_1(x_1) = \frac{1}{N} \sum_{k=1}^N p_1(x_1 | x_0^{(k)}).$$

Nous cherchons alors à évaluer sous quelle condition sur $\sigma(1)$ cette densité p_1 approche la densité $p_{\mathcal{N}}$ de la distribution $\mathcal{N}(0, \sigma^2(1) \cdot I)$. Pour quantifier cet écart, nous introduisons la distance entre ces deux densités :

$$D = \int_{\mathbb{R}^d} (p_1(x) - p_{\mathcal{N}}(x))^2 dx.$$

Puisque les images de notre jeu de données sont des réalisations de variables aléatoires i.i.d. de distribution $\mathbb{P}_{\text{data}}$, la distance D est elle-même une variable aléatoire. Pour obtenir un critère robuste et indépendant de l'échantillon tiré, nous cherchons à minimiser son espérance sur le tirage des données :

$$\mathbb{E}_{x_0^{(1)}, \dots, x_0^{(N)} \text{ i.i.d. } \mathbb{P}_{\text{data}}} [D].$$

Pour calculer et minimiser cette espérance, nous nous appuyons sur le lemme suivant :

Lemme 5.15. *Soient p_a et p_b les densités respectives des lois gaussiennes*

$$\mathcal{N}(a, \sigma^2(1) \cdot I) \quad \text{et} \quad \mathcal{N}(b, \sigma^2(1) \cdot I),$$

Alors

$$\int_{\mathbb{R}^d} p_a(X) p_b(X) dX = \frac{1}{(4\pi\sigma^2(1))^{d/2}} \exp\left(-\frac{\|a - b\|_2^2}{4\sigma^2(1)}\right).$$

Démonstration. Par définition,

$$p_a(X) = \frac{1}{(2\pi\sigma^2(1))^{d/2}} \exp\left(-\frac{\|X - a\|_2^2}{2\sigma^2(1)}\right)$$

et

$$p_b(X) = \frac{1}{(2\pi\sigma^2(1))^{d/2}} \exp\left(-\frac{\|X - b\|_2^2}{2\sigma^2(1)}\right).$$

Ainsi,

$$\int_{\mathbb{R}^d} p_a(X)p_b(X) dx = \frac{1}{(2\pi\sigma^2(1))^d} \int_{\mathbb{R}^d} \exp\left(-\frac{\|X - a\|_2^2 + \|X - b\|_2^2}{2\sigma^2(1)}\right) dx.$$

De plus,

$$\begin{aligned} \|X - a\|_2^2 + \|X - b\|_2^2 &= \|X - a\|_2^2 + \|X - a + a - b\|_2^2 \\ &= 2\|X - a\|_2^2 + 2(X - a)^\top(a - b) + \|a - b\|_2^2 \end{aligned}$$

Or, $\|c + \frac{d}{2}\|_2^2 = \|c\|_2^2 + c^\top d + \frac{\|d\|_2^2}{4}$, donc $2\|c + \frac{d}{2}\|_2^2 + \frac{\|d\|_2^2}{2} = 2\|c\|_2^2 + 2c^\top d + \|d\|_2^2$. Ainsi avec $c = X - a$ et $d = a - b$ on obtient :

$$\|X - a\|_2^2 + \|X - b\|_2^2 = 2\left\|X - a + \frac{a - b}{2}\right\|_2^2 + \frac{\|a - b\|_2^2}{2}.$$

On en déduit

$$\begin{aligned} \int_{\mathbb{R}^d} p_a(X)p_b(X) dX &= \frac{\exp\left(-\frac{\|a-b\|_2^2}{4\sigma^2(1)}\right)}{(2\pi\sigma^2(1))^d} \int_{\mathbb{R}^d} \exp\left(-\frac{\|X - \frac{a+b}{2}\|_2^2}{\sigma^2(1)}\right) dX \\ &= \frac{(\pi\sigma^2(1))^{d/2}}{(2\pi\sigma^2(1))^d} \exp\left(-\frac{\|a-b\|_2^2}{4\sigma^2(1)}\right) \int_{\mathbb{R}^d} \frac{1}{(\pi\sigma^2(1))^{d/2}} \exp\left(-\frac{\|X - \frac{a+b}{2}\|_2^2}{\sigma^2(1)}\right) dX \\ &= \frac{1}{(4\pi\sigma^2(1))^{d/2}} \exp\left(-\frac{\|a-b\|_2^2}{4\sigma^2(1)}\right) \int_{\mathbb{R}^d} \frac{1}{(\pi\sigma^2(1))^{d/2}} \exp\left(-\frac{\|X - \frac{a+b}{2}\|_2^2}{\sigma^2(1)}\right) dX. \end{aligned}$$

En reconnaissant la densité de la loi normale $N(\frac{a+b}{2}, \frac{\sigma^2(1)}{2} \cdot I)$:

$$\int_{\mathbb{R}^d} p_a(X)p_b(X) dX = \frac{1}{(4\pi\sigma^2(1))^{d/2}} \exp\left(-\frac{\|a-b\|_2^2}{4\sigma^2(1)}\right)$$

□

On a alors le théorème suivant.

Théorème 5.16. Soient $X_0^{(1)}, \dots, X_0^{(N)}$ des variables aléatoires i.i.d. de loi $\mathbb{P}_{\text{data}}$. On pose alors

$$D' = \int_{\mathbb{R}^d} (p_1(X) - p_{\mathcal{N}}(X))^2 dX,$$

où :

$$p_1(X) = \frac{1}{N} \sum_{k=1}^N p_1(X \mid X_0^{(k)}) \quad \text{et} \quad p_{\mathcal{N}}(X) = \frac{1}{(2\pi\sigma^2(1))^{d/2}} \exp\left(-\frac{\|X\|_2^2}{2\sigma^2(1)}\right).$$

Alors

$$\begin{aligned} & \mathbb{E}_{X_0^{(1)}, \dots, X_0^{(N)} \stackrel{\text{i.i.d.}}{\sim} \mathbb{P}_{\text{data}}} [D'] \\ &= \frac{1}{(4\pi\sigma^2(1))^{d/2}} \left[\frac{1}{N} + \frac{N-1}{N} \mathbb{E}_{X_0^{(i)}, X_0^{(j)} \stackrel{\text{i.i.d.}}{\sim} \mathbb{P}_{\text{data}}} \left[\exp \left(-\frac{\|X_0^{(i)} - X_0^{(j)}\|_2^2}{4\sigma^2(1)} \right) \right] - 2 \mathbb{E}_{X_0^{(i)} \sim \mathbb{P}_{\text{data}}} \left[\exp \left(-\frac{\|X_0^{(i)}\|_2^2}{4\sigma^2(1)} \right) \right] + 1 \right]. \end{aligned}$$

Démonstration. Dans la démonstration, on note $\mathbb{E}[\cdot]$ à la place de $\mathbb{E}_{X_0^{(1)}, \dots, X_0^{(N)} \stackrel{\text{i.i.d.}}{\sim} \mathbb{P}_{\text{data}}} [\cdot]$.

Par développement du carré,

$$D' = \int_{\mathbb{R}^d} p_1(X)^2 dX - 2 \int_{\mathbb{R}^d} p_1(X) p_{\mathcal{N}}(X) dX + \int_{\mathbb{R}^d} p_{\mathcal{N}}(X)^2 dX.$$

Par linéarité de l'espérance :

$$\mathbb{E}[D'] = \mathbb{E} \left[\int_{\mathbb{R}^d} p_1(X)^2 dX \right] - 2 \mathbb{E} \left[\int_{\mathbb{R}^d} p_1(X) p_{\mathcal{N}}(X) dX \right] + \mathbb{E} \left[\int_{\mathbb{R}^d} p_{\mathcal{N}}(X)^2 dX \right].$$

Nous calculons séparément chacun des trois termes.

1. Calcul de $\mathbb{E} \left[\int_{\mathbb{R}^d} p_{\mathcal{N}}(X)^2 dX \right]$.

Etant donné que $p_{\mathcal{N}}$ est la densité de la loi $\mathcal{N}(0, \sigma^2(1) \cdot I)$, d'après le lemme 5.15 avec $a = b = 0$ on a :

$$\int_{\mathbb{R}^d} p_{\mathcal{N}}(X)^2 dX = \frac{1}{(4\pi\sigma^2(1))^{d/2}}$$

donc

$$\mathbb{E} \left[\int_{\mathbb{R}^d} p_{\mathcal{N}}(X)^2 dX \right] = \frac{1}{(4\pi\sigma^2(1))^{d/2}}.$$

2. Calcul du terme croisé.

Par définition,

$$\int_{\mathbb{R}^d} p_1(X) p_{\mathcal{N}}(X) dX = \frac{1}{N} \sum_{k=1}^N \int_{\mathbb{R}^d} p_1(X | X_0^{(k)}) p_{\mathcal{N}}(X) dX.$$

Or les densités $p_1(X | X_0^{(k)})$ et $p_{\mathcal{N}}$ sont les densités respectives des lois normales $\mathcal{N}(X_0^{(k)}, \sigma^2(1) \cdot I)$ et $\mathcal{N}(0, \sigma^2(1) \cdot I)$. Ainsi d'après le lemme 5.15 avec $a = X_0^{(k)}$ et $b = 0$:

$$\int_{\mathbb{R}^d} p_1(X) p_{\mathcal{N}}(X) dX = \frac{1}{(4\pi\sigma^2(1))^{d/2}} \frac{1}{N} \sum_{k=1}^N \exp \left(-\frac{\|X_0^{(k)}\|_2^2}{4\sigma^2(1)} \right).$$

En prenant l'espérance :

$$\mathbb{E} \left[\int_{\mathbb{R}^d} p_1(X) p_{\mathcal{N}}(X) dX \right] = \frac{1}{(4\pi\sigma^2(1))^{d/2}} \frac{1}{N} \sum_{k=1}^N \mathbb{E} \left[\exp \left(-\frac{\|X_0^{(k)}\|_2^2}{4\sigma^2(1)} \right) \right]$$

Or, puisque $X_0^{(1)}, \dots, X_0^{(N)} \stackrel{\text{i.i.d.}}{\sim} \mathbb{P}_{\text{data}}$ on a $\mathbb{E} \left[\exp \left(-\frac{\|X_0^{(1)}\|_2^2}{4\sigma^2(1)} \right) \right] = \dots = \mathbb{E} \left[\exp \left(-\frac{\|X_0^{(N)}\|_2^2}{4\sigma^2(1)} \right) \right]$ donc pour $i \in \llbracket 1, N \rrbracket$,

$$\frac{1}{(4\pi\sigma^2(1))^{d/2}} \frac{1}{N} \sum_{k=1}^N \mathbb{E} \left[\exp \left(-\frac{\|X_0^{(k)}\|_2^2}{4\sigma^2(1)} \right) \right] = \frac{1}{(4\pi\sigma^2(1))^{d/2}} \mathbb{E} \left[\exp \left(-\frac{\|X_0^{(i)}\|_2^2}{4\sigma^2(1)} \right) \right].$$

Ainsi,

$$\mathbb{E} \left[\int_{\mathbb{R}^d} p_1(X) p_{\mathcal{N}}(X) dX \right] = \frac{1}{(4\pi\sigma^2(1))^{d/2}} \mathbb{E} \left[\exp \left(-\frac{\|X_0^{(i)}\|_2^2}{4\sigma^2(1)} \right) \right].$$

Par conséquent,

$$2\mathbb{E} \left[\int_{\mathbb{R}^d} p_1(X) p_{\mathcal{N}}(X) dX \right] = \frac{2}{(4\pi\sigma^2(1))^{d/2}} \mathbb{E}_{X_0^{(i)} \sim \mathbb{P}_{\text{data}}} \left[\exp \left(-\frac{\|X_0^{(i)}\|_2^2}{4\sigma^2(1)} \right) \right].$$

3. Calcul de $\int_{\mathbb{R}^d} p_1(X)^2 dX$.

On a

$$p_1(X)^2 = \left(\frac{1}{N} \sum_{k=1}^N p_1(X | X_0^{(k)}) \right)^2 = \frac{1}{N^2} \sum_{k=1}^N \sum_{l=1}^N p_1(X | X_0^{(k)}) p_1(X | X_0^{(l)})$$

Ainsi,

$$\int_{\mathbb{R}^d} p_1(X)^2 dX = \frac{1}{N^2} \sum_{k=1}^N \sum_{l=1}^N \int_{\mathbb{R}^d} p_1(X | X_0^{(k)}) p_1(X | X_0^{(l)}) dX.$$

Or, les densités $p_1(X | X_0^{(k)})$ et $p_1(X | X_0^{(l)})$ sont les densités respectives des lois normales $\mathcal{N}(X_0^{(k)}, \sigma^2(1) \cdot I)$ et $\mathcal{N}(X_0^{(l)}, \sigma^2(1) \cdot I)$. Ainsi d'après le lemme 5.15 avec $a = X_0^{(k)}$ et $b = X_0^{(l)}$

$$\int_{\mathbb{R}^d} p_1(X)^2 dX = \frac{1}{(4\pi\sigma^2(1))^{d/2}} \frac{1}{N^2} \sum_{k=1}^N \sum_{l=1}^N \exp \left(-\frac{\|X_0^{(k)} - X_0^{(l)}\|_2^2}{4\sigma^2(1)} \right).$$

Ainsi en prenant l'espérance :

$$\mathbb{E} \left[\int_{\mathbb{R}^d} p_1(X)^2 dX \right] = \frac{1}{(4\pi\sigma^2(1))^{d/2}} \frac{1}{N^2} \sum_{k=1}^N \sum_{l=1}^N \mathbb{E} \left[\exp \left(-\frac{\|X_0^{(k)} - X_0^{(l)}\|_2^2}{4\sigma^2(1)} \right) \right].$$

Pour $k = l$, il y a N termes égaux à 1.

Pour $k \neq l$, il y a $N(N-1)$ termes de même espérance,

$$\mathbb{E} \left[\exp \left(-\frac{\|X_0^{(i)} - X_0^{(j)}\|_2^2}{4\sigma^2(1)} \right) \right].$$

où $(i, j) \in \llbracket 1, N \rrbracket^2$ avec $i \neq j$.

On obtient donc

$$\mathbb{E} \left[\int_{\mathbb{R}^d} p_1(X)^2 dX \right] = \frac{1}{(4\pi\sigma^2(1))^{d/2}} \left[\frac{1}{N} + \frac{N-1}{N} \mathbb{E}_{X_0^{(i)}, X_0^{(j)} \text{ i.i.d. } \mathbb{P}_{\text{data}}} \left[\exp \left(-\frac{\|X_0^{(i)} - X_0^{(j)}\|_2^2}{4\sigma^2(1)} \right) \right] \right].$$

En réunissant les trois calculs précédents on obtient,

$$\mathbb{E}[D'] = \frac{1}{(4\pi\sigma^2(1))^{d/2}} \left[\frac{1}{N} + \frac{N-1}{N} \mathbb{E}_{X_0^{(i)}, X_0^{(j)} \text{ i.i.d. } \mathbb{P}_{\text{data}}} \left[\exp \left(-\frac{\|X_0^{(i)} - X_0^{(j)}\|_2^2}{4\sigma^2(1)} \right) \right] - 2\mathbb{E}_{X_0^{(i)} \sim \mathbb{P}_{\text{data}}} \left[\exp \left(-\frac{\|X_0^{(i)}\|_2^2}{4\sigma^2(1)} \right) \right] + 1 \right].$$

□

Ainsi d'après le théorème :

$$\begin{aligned} & \mathbb{E}_{x_0^{(1)}, \dots, x_0^{(N)} \stackrel{\text{i.i.d.}}{\sim} \mathbb{P}_{\text{data}}} [D] \\ &= \frac{1}{(4\pi\sigma^2(1))^{d/2}} \left[\frac{1}{N} + \frac{N-1}{N} \mathbb{E}_{x_0^{(i)}, x_0^{(j)} \stackrel{\text{i.i.d.}}{\sim} \mathbb{P}_{\text{data}}} \left[\exp \left(-\frac{\|x_0^{(i)} - x_0^{(j)}\|_2^2}{4\sigma^2(1)} \right) \right] - 2 \mathbb{E}_{x_0^{(i)} \sim \mathbb{P}_{\text{data}}} \left[\exp \left(-\frac{\|x_0^{(i)}\|_2^2}{4\sigma^2(1)} \right) \right] + 1 \right]. \end{aligned}$$

On remarque alors que lorsque,

$$\frac{\|x_0^{(i)} - x_0^{(j)}\|_2^2}{4\sigma^2(1)} \longrightarrow 0 \quad \text{et} \quad \frac{\|x_0^{(i)}\|_2^2}{4\sigma^2(1)} \longrightarrow 0$$

On a :

$$\mathbb{E}_{x_0^{(1)}, \dots, x_0^{(N)} \stackrel{\text{i.i.d.}}{\sim} \mathbb{P}_{\text{data}}} [D] \longrightarrow \frac{1}{(4\pi\sigma^2(1))^{d/2}} \left[\frac{1}{N} + \frac{N-1}{N} \times 1 - 2 \times 1 + 1 \right] = 0$$

Ainsi on obtient que $\mathbb{E}_{x_0^{(1)}, \dots, x_0^{(N)} \stackrel{\text{i.i.d.}}{\sim} \mathbb{P}_{\text{data}}} [D]$ devient arbitrairement petit lorsque :

$$\frac{\|x_0^{(i)} - x_0^{(j)}\|_2^2}{4\sigma^2(1)} \ll 1 \quad \text{et} \quad \frac{\|x_0^{(i)}\|_2^2}{4\sigma^2(1)} \ll 1$$

c'est-à-dire lorsque :

$$\frac{\|x_0^{(i)} - x_0^{(j)}\|_2}{2} \ll \sigma(1) \quad \text{et} \quad \frac{\|x_0^{(i)}\|_2}{2} \ll \sigma(1).$$

Puisque la seconde condition est moins sélective que la première, il suffit donc que :

$$\frac{\|x_0^{(i)} - x_0^{(j)}\|_2}{2} \ll \sigma(1)$$

soit,

$$\frac{1}{2} \max_{i,j} \|x_0^{(i)} - x_0^{(j)}\|_2 \ll \sigma(1).$$

Ainsi pour que la loi de x_1 approxime la loi normale $\mathcal{N}(0, \sigma^2(1) \cdot I)$, il faut que $\sigma(1) \gg \frac{1}{2} \max_{i,j} \|x_0^{(i)} - x_0^{(j)}\|_2$

En pratique, il n'est pas nécessaire de choisir un niveau de bruit $\sigma(1)$ beaucoup plus grand que la borne précédente. En effet, l'approximation suffit lorsque

$$\sigma(1) = \max_{i,j} \|x_0^{(i)} - x_0^{(j)}\|_2.$$

On cherche maintenant $\sigma(0)$.

5.1.6 Détermination de $\sigma(0)$

Idéalement, le processus de débruitage devrait ramener le niveau de bruit exactement à zéro afin que l'image générée ne présente aucun défaut résiduel, ce qui correspondrait à $\sigma(0) = 0$.

Cependant, cette limite pose un problème d'ordre théorique et numérique. En effet, si $\sigma(t) \longrightarrow 0$, la loi conditionnelle

$$x_t \mid x_0 \sim \mathcal{N}(x_0, \sigma^2(t) \cdot I)$$

dégénère en une loi de Dirac centrée en x_0 . Or, la mesure de Dirac ne possédant pas de densité par rapport à la mesure de Lebesgue, la notion même de score $\nabla_x \log p_t$ devient mathématiquement mal définie en $t = 0$.

Cette singularité s’observe d’ailleurs directement sur l’expression explicite du score conditionnel :

$$\nabla_x \log p_t(x_t | x_0) = -\frac{x_t - x_0}{\sigma^2(t)},$$

qui diverge lorsque $\sigma(t) \rightarrow 0$. Lors de l’entraînement et de la génération, cette explosion des valeurs rendrait les calculs instables et empêcherait la convergence de l’algorithme.

Afin de contourner cette singularité, on impose une borne minimale pour le bruit :

$$\sigma(0) = \sigma_{\min} > 0.$$

En pratique, une valeur de l’ordre de $\sigma(0) = 0.01$ permet de conserver des scores bien définis et d’assurer la stabilité numérique, tout en maintenant un niveau de bruit résiduel suffisamment faible pour être imperceptible sur l’image générée.

Il ne reste plus qu’à trouver $\sigma(t)$.

5.1.7 Détermination de $\sigma(t)$

Bien que le choix du schéma d’évolution du bruit $\sigma(t)$ repose historiquement sur des succès empiriques, il est possible de le justifier par un objectif analytique précis.

Lors de l’optimisation, la variable de temps t est échantillonnée selon une loi uniforme sur l’intervalle $[0,1]$. L’objectif de notre schéma est de faire correspondre cette mesure temporelle uniforme à une exploration uniforme des ordres de grandeur du bruit. Mathématiquement, cela revient à imposer que la fonction $t \mapsto \log \sigma(t)$ soit affine.

En d’autres termes, un incrément temporel constant dt doit se traduire par une variation relative constante du niveau de bruit. Cette condition se caractérise par l’équation différentielle suivante, où $k > 0$ est une constante :

$$\frac{d\sigma(t)}{\sigma(t)} = k dt$$

Résolvons cette équation pour expliciter ce schéma de bruit. En intégrant, on obtient :

$$\log \sigma(t) = k t + C$$

où C est une constante d’intégration. En appliquant la fonction exponentielle, la forme générale s’écrit :

$$\sigma(t) = \exp(C) \exp(kt)$$

Les constantes se déterminent grâce aux bornes fixées. En $t = 0$ nous avons $\sigma(0) = \exp(C)$. En $t = 1$, la condition $\sigma(1) = \sigma(0) \exp(k)$ implique :

$$k = \log \left(\frac{\sigma(1)}{\sigma(0)} \right)$$

En substituant ces paramètres, nous aboutissons à l’expression finale :

$$\sigma(t) = \sigma(0) \times \left(\frac{\sigma(1)}{\sigma(0)} \right)^t$$

Ce choix particulier de $\sigma(t)$, appelé **geometric noise schedule**, est donc l’unique solution satisfaisant cette condition de variation relative constante, justifiant formellement son efficacité en pratique.

Maintenant que nous avons déterminé la fonction de bruitage σ , nous pouvons générer des images $\hat{x}_1$ suivant la distribution $\mathbb{P}_{\text{data}}$ grâce à (7) et à des images bruitées $\hat{x}_0$ suivant la distribution $\mathcal{N}(0, \sigma^2(1) \cdot I)$. Nous pouvons ainsi passer à l’implémentation du modèle.

5.1.8 Implémentation du modèle

Pour des raisons de puissance de calcul, dans la suite de ce document nous utiliserons comme jeu de données des gaussiennes et des spirales plutôt que des ensembles d'images. Ainsi en choisissant comme jeu de données 8 gaussiennes, on obtient en implémentant le modèle :




FIGURE 1 – Tentative de génération de gaussiennes.

Ainsi, on remarque avec la figure 1 que bien que la méthode soit correcte théoriquement, l'algorithme ne génère pas de gaussiennes. Pour savoir ce qui pose problème, on regarde comment le score network s_θ approxime le score $\nabla_x \log p_t$. Dans le cas d'un jeu de données très simple comme des gaussiennes, on peut en réalité obtenir la distribution $\mathbb{P}_{\text{data}}$ et donc calculer directement le score $\nabla_x \log p_t$. On peut alors comparer $\nabla_x \log p_t$ approximé et $\nabla_x \log p_t$ calculé :




FIGURE 2 – Evolution des erreurs d'approximation du score.

On remarque avec la figure 2 que l'approximation de $\nabla_x \log p_t$ par s_θ est très mauvaise. Pour savoir pourquoi on s'intéresse au terme à minimiser $l(\theta)$:




FIGURE 3 – Evolution de la moyenne de $l(\theta)$.

On observe alors avec la figure 3 que lors de l'entraînement, le terme $l(\theta)$ varie entre des valeurs trop grandes. Puisque l'on cherche à minimiser $l(\theta)$, la courbe devrait varier entre des valeurs beaucoup plus faibles, idéalement les plus proches de 0 possible. Le problème n'est donc pas dû à la méthode utilisée mais au programme choisi pour minimiser $l(\theta)$. L'algorithme utilisé pour minimiser $l(\theta)$ est un algorithme de descente de gradient et $l(\theta)$ possède comme gradient :

$$\nabla_{\theta} l(\theta) = \mathbb{E}_{x_0} \mathbb{E}_t \mathbb{E}_{x_t \sim \mathcal{N}(x_0, \sigma^2(t) \cdot I)} \left[J_{s_{\theta}}(x_t, t)^{\top} \left(s_{\theta}(x_t, t) + \frac{x_t - x_0}{\sigma^2(t)} \right) \right]$$

où $J_{s_{\theta}}(x_t, t)$ est la matrice jacobienne de s_{θ} . On voit alors que $\nabla_{\theta} l$ dépend du terme $\frac{x_t - x_0}{\sigma^2(t)}$. De plus,

$$\frac{x_t - x_0}{\sigma^2(t)} = \frac{Z}{\sigma(t)} = \mathcal{O}\left(\frac{1}{\sigma(t)}\right).$$

Ainsi, les valeurs du gradient sont beaucoup plus grandes pour des bruits faibles que pour des bruits plus importants.

Or, l'algorithme de descente de gradient met à jour les paramètres du réseau à partir de la moyenne des gradients. Les gradients de grandes valeurs influencent donc fortement cette moyenne et par conséquent orientent fortement les mises à jour des paramètres. Ainsi dans notre cas, s_{θ} est davantage entraîné pour des bruits faibles que pour des bruits plus importants, on peut le voir avec la figure 2 où l'erreur relative est minimale pour des bruits faibles. Cependant, ce que l'on cherche c'est que s_{θ} soit entraîné de la même manière qu'importe le bruit. Pour uniformiser l'entraînement, on ajoute alors le terme de pondération $\sigma^2(t)$ à $l(\theta)$. On a alors :

$$\begin{aligned} L(\theta) &= \frac{1}{2} \mathbb{E}_{x_0} \mathbb{E}_t \mathbb{E}_{x_t \sim \mathcal{N}(x_0, \sigma^2(t) \cdot I)} \left[\sigma^2(t) \left\| s_{\theta}(x_t, t) + \frac{x_t - x_0}{\sigma^2(t)} \right\|_2^2 \right] \\ &= \frac{1}{2} \mathbb{E}_{x_0} \mathbb{E}_t \mathbb{E}_{x_t \sim \mathcal{N}(x_0, \sigma^2(t) \cdot I)} \left[\left\| \sigma(t) s_{\theta}(x_t, t) + \frac{x_t - x_0}{\sigma(t)} \right\|_2^2 \right] \\ &= \frac{1}{2} \mathbb{E}_{x_0} \mathbb{E}_t \mathbb{E}_{x_t \sim \mathcal{N}(x_0, \sigma^2(t) \cdot I)} \left[\left\| \sigma(t) s_{\theta}(x_t, t) + Z \right\|_2^2 \right]. \end{aligned}$$

On obtient alors le gradient :

$$\begin{aligned}\nabla_{\theta} L(\theta) &= \mathbb{E}_{x_0} \mathbb{E}_t \mathbb{E}_{x_t \sim \mathcal{N}(x_0, \sigma^2(t) \cdot I)} \left[J_{s_{\theta}}(x_t, t)^{\top} (\sigma^2(t) s_{\theta}(x_t, t) + \sigma(t) Z) \right] \\ &= \mathbb{E}_{x_0} \mathbb{E}_t \mathbb{E}_{x_t \sim \mathcal{N}(x_0, \sigma^2(t) \cdot I)} \left[\sigma(t) J_{s_{\theta}}(x_t, t)^{\top} (\sigma(t) s_{\theta}(x_t, t) + Z) \right].\end{aligned}$$

Ainsi, en posant le nouveau réseau neuronal $z_{\theta} = -\sigma(t)s_{\theta}$, on a $J_{s_{\theta}}(x_t, t)^{\top} = -\frac{1}{\sigma(t)} J_{z_{\theta}}(x_t, t)^{\top}$ d'où :

$$\nabla_{\theta} L(\theta) = \mathbb{E}_{x_0} \mathbb{E}_t \mathbb{E}_{x_t \sim \mathcal{N}(x_0, \sigma^2(t) \cdot I)} \left[J_{z_{\theta}}(x_t, t)^{\top} (z_{\theta}(x_t, t) - Z) \right].$$

On obtient donc que $\nabla_{\theta} L(\theta)$ ne dépend plus explicitement du bruit $\sigma(t)$. Ainsi, on peut entraîner le réseau neuronal z_{θ} à approximer Z sans le problème lié au bruit $\sigma(t)$. On déduit ensuite le score network avec $s_{\theta} = -\frac{z_{\theta}}{\sigma(t)}$.

En implémentant la méthode en utilisant comme réseau neuronal z_{θ} , on obtient :




FIGURE 4 – Evolution de la moyenne de $L(\theta)$.

On obtient alors que contrairement à la courbe de la figure 3, la courbe de la figure 4 finit bien par se stabiliser autour d'une valeur plus proche de 0. La minimisation de $L(\theta)$ est donc correcte. On regarde alors si le score network s_{θ} déduit approxime bien $\nabla_x \log p_t$:




FIGURE 5 – Evolution des erreurs d'approximation du score avec $L(\theta)$.

On observe avec la figure 5 que l'approximation de $\nabla_x \log p_t$ est nettement meilleure en minimisant $L(\theta)$. En particulier, on remarque que contrairement à l'erreur relative de la figure 2 qui était minimale pour des bruits faibles, l'erreur relative de la figure 5 est minimale pour des bruits plus forts. On essaie alors à nouveau la génération :




FIGURE 6 – Génération de gaussiennes.

Si on prend comme jeu de données une spirale plutôt que des gaussiennes :




FIGURE 7 – Génération d'une spirale.

Ainsi, on voit avec les figures 6 et 7 que la génération est correcte.

Néanmoins, bien que le modèle SGM fonctionne pour générer des images, ce modèle présente un problème majeur lié aux trajectoires de l'EDS inverse.

En effet, les trajectoires sont de la forme :




FIGURE 8 – Exemple de trajectoires de l'EDS inverse.

Comme l'illustre la figure 8, les trajectoires de l'EDS inverse sont fortement irrégulières. Les images générées ne sont donc pas obtenues par un transport direct vers la distribution cible, mais suivent des trajectoires sinueuses sous l'effet du terme stochastique

$$\sqrt{\left| \frac{d[\sigma^2(u)]}{du} \right|_{u=1-t}}, d\bar{B}_t.$$

Ces détours rendent le processus de génération moins efficace et contribuent à augmenter son temps de calcul. En effet, les trajectoires étant peu régulières, le pas de temps doit être choisi suffisamment faible afin de limiter l'erreur de discrétisation. Le nombre d'étapes de résolution augmente alors, ce qui ralentit la génération des images. Cette observation motive la recherche d'un processus de génération reposant sur une équation ne comportant plus ce terme stochastique, afin d'obtenir des trajectoires plus régulières et plus directes.

5.2 Probability Flow

Le modèle appelé **Probability Flow** se distingue du modèle SGM par l'utilisation d'une équation différentielle ordinaire (EDO), plutôt qu'une EDS, pour la génération.

5.2.1 Obtention du processus de génération

Pour obtenir l'EDO recherchée, on a besoin du théorème :

Théorème 5.17. *Soit $(X_t)_{t \in [0, T]}$ la solution de l'équation différentielle stochastique*

$$dX_t = f(X_t, t) dt + g(t) dB_t,$$

où $(B_t)_{t \in [0, T]}$ est un mouvement brownien standard, $f : \mathbb{R}^d \times [0, T] \rightarrow \mathbb{R}^d$ et $g : [0, T] \rightarrow \mathbb{R}$ deux fonctions régulières.

On suppose que, pour tout $t \in [0, T]$, la variable aléatoire X_t admet une densité marginale p_t strictement positive sur $\mathbb{R}^d$ et suffisamment régulière.

Soit $(Y_t)_{t \in [0, T]}$ la solution de l'équation différentielle ordinaire

$$\frac{dY_t}{dt} = f(Y_t, t) - \frac{1}{2}g(t)^2 \nabla_X \log p_t(Y_t)$$

avec

$$Y_0 \sim X_0.$$

On suppose également que, pour tout $t \in [0, T]$, la variable aléatoire Y_t admet une densité marginale q_t sur $\mathbb{R}^d$ suffisamment régulière.

Alors, les processus stochastiques $(X_t)_{t \in [0, T]}$ et $(Y_t)_{t \in [0, T]}$ possèdent les mêmes densités marginales.

Démonstration. Soit $(p_t)_{t \in [0, T]}$ la famille des densités marginales du processus stochastique $(X_t)_{t \in [0, T]}$.

D'après l'équation de Fokker–Planck,

$$\partial_t p_t = -\nabla \cdot (f p_t) + \frac{1}{2}g(t)^2 \Delta p_t.$$

Or, on a

$$\Delta p_t = \nabla \cdot (p_t \nabla \log p_t),$$

car

$$p_t \nabla \log p_t = \nabla p_t,$$

et en prenant la divergence,

$$\nabla \cdot (p_t \nabla \log p_t) = \nabla \cdot (\nabla p_t) = \Delta p_t.$$

Ainsi,

$$\partial_t p_t = -\nabla \cdot (f p_t) + \frac{1}{2}g(t)^2 \nabla \cdot (p_t \nabla \log p_t).$$

En regroupant les termes sous une même divergence, on obtient

$$\partial_t p_t = -\nabla \cdot \left[\left(f - \frac{1}{2}g(t)^2 \nabla \log p_t \right) p_t \right].$$

Autrement dit,

$$\partial_t p_t + \nabla \cdot \left(p_t \left(f - \frac{1}{2}g(t)^2 \nabla \log p_t \right) \right) = 0.$$

D'autre part, soit $(Y_t)_{t \in [0, T]}$ la solution de l'EDO

$$\frac{dY_t}{dt} = f(Y_t, t) - \frac{1}{2}g(t)^2 \nabla \log p_t(Y_t),$$

et soit $(q_t)_{t \in [0, T]}$ la famille de ses densités marginales.

D'après l'équation de continuité :

$$\partial_t q_t + \nabla \cdot \left(q_t \left(f - \frac{1}{2}g(t)^2 \nabla \log p_t \right) \right) = 0.$$

Comme

$$Y_0 \sim X_0,$$

on a

$$q_0 = p_0.$$

Les densités (p_t) et (q_t) satisfont donc la même équation de continuité avec la même condition initiale.

Sous les hypothèses de régularité assurant l'unicité de la solution de l'équation de continuité, on obtient donc

$$q_t = p_t, \quad \forall t \in [0, T].$$

c'est-à-dire que les processus stochastiques $(X_t)_{t \in [0, T]}$ et $(Y_t)_{t \in [0, T]}$ possèdent les mêmes densités marginales $\square$

Corollaire 5.18. *Soit $(X_t)_{t \in [0, 1]}$ la solution de l'équation différentielle stochastique*

$$dX_t = \sqrt{\frac{d[\sigma^2(t)]}{dt}} dB_t,$$

où $(B_t)_{t \in [0, 1]}$ est un mouvement brownien standard.

Soit $(Y_t)_{t \in [0, 1]}$ la solution de l'équation différentielle ordinaire

$$\frac{dY_t}{dt} = -\frac{1}{2} \frac{d[\sigma^2(t)]}{dt} \nabla_X \log p_t(Y_t)$$

avec

$$Y_0 \sim X_0.$$

Alors, les processus stochastiques $(X_t)_{t \in [0, 1]}$ et $(Y_t)_{t \in [0, 1]}$ possèdent les mêmes densités marginales.

Démonstration. En appliquant le théorème 5.17 avec $T=1$, $f(x, t) = 0$ et $g(t) = \sqrt{\frac{d[\sigma^2(t)]}{dt}}$, on obtient que la solution $(Y_t)_{t \in [0, 1]}$ de l'EDO :

$$\frac{dY_t}{dt} = -\frac{1}{2} \frac{d[\sigma^2(t)]}{dt} \nabla_X \log p_t(Y_t)$$

possède les mêmes densités marginales que le processus stochastique $(X_t)_{t \in [0, 1]}$. $\square$

Afin de se conformer au schéma, dans la suite de ce mémoire, nous noterons de nouveau $(x_t)_{t \in [0, 1]}$ plutôt que $(y_t)_{t \in [0, 1]}$ nos images bruitées.

L'EDO associée au processus de bruitage est donc :

$$\frac{dx_t}{dt} = -\frac{1}{2} \frac{d[\sigma^2(t)]}{dt} \nabla_x \log p_t(x_t). \quad (10)$$

Ainsi, puisque (10) possède les mêmes densités marginales que (6), si on trouve un processus inverse $(\hat{x}_t)_{t \in [0, 1]}$ au processus $(x_t)_{t \in [0, 1]}$, on aura nécessairement $\hat{x}_1 \sim \mathbb{P}_{\text{data}}$ permettant ainsi d'échantillonner $\mathbb{P}_{\text{data}}$.

Contrairement au modèle SGM, on n'a pas besoin d'un théorème pour trouver l'équation inverse. En effet, une EDO décrit une certaine trajectoire. Ainsi, si l'on veut parcourir la même trajectoire mais dans le sens inverse, on a juste à inverser le temps. On obtient alors que l'EDO recherchée est :

$$\frac{d\hat{x}_t}{dt} = \frac{1}{2} \frac{d[\sigma^2(u)]}{du} \Big|_{u=1-t} \nabla_x \log p_{1-t}(\hat{x}_t). \quad (11)$$

On remarque donc que comme voulu, l'EDO (11) ne présente pas le terme $\sqrt{\frac{d[\sigma^2(u)]}{du}} \Big|_{u=1-t} d\bar{B}_t$.

De plus, en intégrant entre $t = 0$ et $t = 1$ l'équation (11),

$$\hat{x}_1 = \hat{x}_0 + \frac{1}{2} \int_0^1 \frac{d[\sigma^2(u)]}{du} \Big|_{u=1-t} \nabla_x \log p_{1-t}(\hat{x}_t) dt$$

soit avec le changement de variable $t \mapsto 1 - t$,

$$\hat{x}_1 = \hat{x}_0 + \frac{1}{2} \int_0^1 \frac{d[\sigma^2(t)]}{dt} \nabla_x \log p_t(\hat{x}_{1-t}) dt. \quad (12)$$

Finalement, les seuls termes de (12) à déterminer sont la fonction σ et le score $\nabla_x \log p_t$. Pour cela, de la même manière que le modèle SGM, on approxime $\nabla_x \log p_t$ avec le Denoising Score Matching de la section 5.1.3 et on choisit pour σ le geometric noise schedule de la section 5.1.7. Ainsi, on peut maintenant générer des images $\hat{x}_1$ suivant approximativement la distribution $\mathbb{P}_{\text{data}}$ grâce à des images bruitées $\hat{x}_0$ et (12).

De plus, sous des hypothèses suffisantes de régularité sur le score $\nabla_x \log p_t$, la fonction $(t, x) \mapsto \frac{1}{2} \frac{d[\sigma^2(u)]}{du} \Big|_{u=1-t} \nabla_x \log p_{1-t}(x)$ est localement lipschitzienne. Le théorème de Cauchy–Lipschitz garantit alors l’existence et l’unicité de la solution de l’équation différentielle ordinaire (11). Ainsi, pour une image initiale $\hat{x}_0$ donnée, l’image générée $\hat{x}_1$ est unique.

On peut dorénavant comparer la génération entre les méthodes SGM et Probability Flow.

5.2.2 Différence entre les modèles SGM et Probability Flow

On obtient que les trajectoires sont de la forme :




FIGURE 9 – Exemple de trajectoires de l’EDO avec le modèle Probability Flow.

Comme l’illustre la figure 9, les trajectoires du modèle Probability Flow sont lisses et déterministes. Sous des hypothèses suffisantes de régularité, deux trajectoires ne peuvent donc pas se croiser : à une image initiale donnée correspond une unique trajectoire, et par conséquent une unique image générée. Le processus de génération définit ainsi un flot reliant la distribution normale initiale à la distribution des données.

Cependant, ces trajectoires sont toujours fortement courbées. Le pas de temps doit donc être choisi suffisamment faible afin de limiter l’erreur de discrétisation, ce qui augmente le nombre d’étapes nécessaires à la génération et ralentit la génération des images. Cette observation motive le développement de modèles produisant des trajectoires plus simples, idéalement rectilignes, afin de transporter les images de manière plus efficace entre les deux distributions.

6 Modèles de Flot

Les modèles de flot sont une famille de modèles génératifs dont le principe consiste à définir un processus continu $(\hat{x}_t)_{t \in [0,1]}$ comme solution d'une EDO gouvernée par un champ de vitesse u_t , vérifiant

$$\frac{d\hat{x}_t}{dt} = u_t(\hat{x}_t).$$

On cherche ainsi à apprendre le champ de vitesse u_t .

De plus, dans la suite de cette section, on suppose que pour tout $t \in [0, 1]$, l'image intermédiaire $\hat{x}_t$ admet une densité marginale p_t sur $\mathbb{R}^d$.

6.1 Flow Matching

6.1.1 Obtention du processus de génération

Le modèle **Flow Matching (FM)** consiste à apprendre directement le champ de vitesse à partir de trajectoires reliant les images $\hat{x}_0$ aux images à générer $\hat{x}_1$. Le choix le plus simple consiste à considérer le segment reliant les images $\hat{x}_0$ aux images $\hat{x}_1$, ce qui conduit à l'interpolation linéaire

$$\hat{x}_t = (1 - t)\hat{x}_0 + t\hat{x}_1.$$

on a alors en dérivant :

$$\frac{d\hat{x}_t}{dt} = \hat{x}_1 - \hat{x}_0$$

On obtient ainsi une EDO. Cependant, on ne peut pas directement utiliser cette EDO pour trouver la transformation recherchée. En effet, le second terme de l'EDO, et donc par conséquent le flot de l'équation, dépendent de $\hat{x}_1$. Or l'image $\hat{x}_1$ est une image générée, elle nous est donc inconnue. Il nous faut donc trouver une autre EDO dont le second terme ne dépend plus de $\hat{x}_1$. Pour cela on a au préalable besoin d'une définition pour que la nouvelle EDO soit bien définie :

Définition 6.1 (Processus à trajectoires absolument continues). *Soit $(X_t)_{t \in [0,T]}$ un processus stochastique à valeurs dans $\mathbb{R}^d$.*

On dit que $(X_t)_{t \in [0,T]}$ est à trajectoires absolument continues si, pour presque tout $\omega \in \Omega$, il existe une fonction

$$V(\cdot, \omega) \in L^1([0, T]; \mathbb{R}^d)$$

telle que

$$X_t(\omega) = X_0(\omega) + \int_0^t V(s, \omega) ds, \quad \forall t \in [0, T].$$

En particulier, la trajectoire est dérivable presque partout sur $[0, T]$ et

$$\frac{d}{dt} X_t(\omega) = V(t, \omega)$$

pour presque tout $t \in [0, T]$.

On peut maintenant trouver l'EDO dont le second terme ne dépend plus de $\hat{x}_1$. Pour cela on a le lemme et le théorème suivant.

Lemme 6.2 (Lemme de Doob-Dynkin). *Soient $(\Omega, \mathcal{F}, \mathbb{P})$ un espace probabilisé et*

$$X : \Omega \longrightarrow E$$

une variable aléatoire à valeurs dans un espace mesurable $(E, \mathcal{E})$.

Soit

$$Y : \Omega \longrightarrow \mathbb{R}^d$$

une variable aléatoire $\sigma(X)$ -mesurable.

Alors il existe une fonction mesurable

$$f : E \longrightarrow \mathbb{R}^d$$

telle que

$$Y = f(X) \quad p.s.$$

Démonstration. Démonstration admise. □

Théorème 6.3. Soit $(\hat{X}_t)_{t \in [0, T]}$ un processus stochastique à trajectoires absolument continues vérifiant

$$\frac{d\hat{X}_t}{dt} = u_t(\hat{X}_t),$$

On suppose que, pour tout $t \in [0, T]$, la variable aléatoire $\hat{X}_t$ admet une densité marginale p_t sur $\mathbb{R}^d$ suffisamment régulière. On définit le champ de vitesse déterministe $v_t : \mathbb{R}^d \mapsto \mathbb{R}^d$ comme l'unique fonction mesurable (à un ensemble de mesure nulle près) telle que :

$$v_t(\hat{X}_t) = \mathbb{E}_t \left[u_t(\hat{X}_t) \mid \hat{X}_t \right] \quad p.s.$$

Soit $(\hat{Y}_t)_{t \in [0, T]}$ la solution de l'équation différentielle ordinaire

$$\frac{d\hat{Y}_t}{dt} = v_t(\hat{Y}_t),$$

avec

$$\hat{Y}_0 \sim \hat{X}_0.$$

On suppose également que, pour tout $t \in [0, T]$, la variable aléatoire $\hat{Y}_t$ admet une densité marginale q_t sur $\mathbb{R}^d$ suffisamment régulière.

Alors, les processus stochastiques $(\hat{X}_t)_{t \in [0, T]}$ et $(\hat{Y}_t)_{t \in [0, T]}$ possèdent les mêmes densités marginales.

Démonstration. Soit $(\hat{Y}_t)_{t \in [0, T]}$ la solution de l'équation différentielle ordinaire

$$\frac{d\hat{Y}_t}{dt} = v_t(\hat{Y}_t), \quad \hat{Y}_0 \sim \hat{X}_0,$$

et notons q_t sa densité marginale.

Sous les hypothèses de régularité, les densités marginales $(q_t)_{t \in [0, T]}$ satisfont l'équation de continuité

$$\partial_t q_t + \nabla \cdot (q_t v_t) = 0,$$

avec comme condition initiale

$$q_0 = p_0.$$

Montrons maintenant que les densités marginales $(p_t)_{t \in [0, T]}$ du processus stochastique $(\hat{X}_t)_{t \in [0, T]}$ vérifient cette même équation.

Soit $\varphi \in C_c^\infty(\mathbb{R}^d)$. Les trajectoires de $(\hat{X}_t)_{t \in [0, T]}$ étant absolument continues,

$$\frac{d}{dt} \varphi(\hat{X}_t) = \nabla \varphi(\hat{X}_t) \cdot u_t(\hat{X}_t).$$

En prenant l'espérance,

$$\frac{d}{dt} \mathbb{E}_t[\varphi(\hat{X}_t)] = \mathbb{E}_t \left[\nabla \varphi(\hat{X}_t) \cdot u_t(\hat{X}_t) \right].$$

En utilisant (i) de la propriété 2.7,

$$\mathbb{E}_t \left[\nabla \varphi(\hat{X}_t) \cdot u_t(\hat{X}_t) \right] = \mathbb{E}_t \left[\mathbb{E}_t \left[\nabla \varphi(\hat{X}_t) \cdot u_t(\hat{X}_t) \mid \hat{X}_t \right] \right].$$

De plus, puisque $\nabla \varphi(\hat{X}_t)$ est $\sigma(\hat{X}_t)$ -mesurable, en utilisant (iii) de la propriété 2.7,

$$\mathbb{E}_t \left[\mathbb{E}_t \left[\nabla \varphi(\hat{X}_t) \cdot u_t(\hat{X}_t) \mid \hat{X}_t \right] \right] = \mathbb{E}_t \left[\nabla \varphi(\hat{X}_t) \cdot U_t(\hat{X}_t) \right]$$

où $U_t(\hat{X}_t) = \mathbb{E}_t \left[u_t(\hat{X}_t) \mid \hat{X}_t \right]$.

Ainsi,

$$\frac{d}{dt} \mathbb{E}_t[\varphi(\hat{X}_t)] = \mathbb{E}_t \left[\nabla \varphi(\hat{X}_t) \cdot U_t(\hat{X}_t) \right].$$

Comme $U_t(\hat{X}_t)$ est $\sigma(\hat{X}_t)$ -mesurable, le lemme de Doob–Dynkin garantit l’existence d’une fonction mesurable

$$v_t : \mathbb{R}^d \longrightarrow \mathbb{R}^d$$

telle que

$$U_t(\hat{X}_t) = v_t(\hat{X}_t) \quad \text{p.s.}$$

On obtient alors

$$\frac{d}{dt} \mathbb{E}_t[\varphi(\hat{X}_t)] = \mathbb{E}_t \left[\nabla \varphi(\hat{X}_t) \cdot v_t(\hat{X}_t) \right]$$

soit, puisque $\hat{X}_t$ admet la densité marginale p_t ,

$$\frac{d}{dt} \int_{\mathbb{R}^d} \varphi(x) p_t(x) dx = \int_{\mathbb{R}^d} \nabla \varphi(x) \cdot v_t(x) p_t(x) dx.$$

Comme p_t est supposée suffisamment régulière, on peut appliquer le théorème de dérivation pour les intégrales à paramètres, on obtient alors,

$$\int_{\mathbb{R}^d} \varphi(x) \partial_t p_t(x) dx = \int_{\mathbb{R}^d} \nabla \varphi(x) \cdot v_t(x) p_t(x) dx.$$

Or,

$$\nabla \cdot (\varphi p_t v_t) = \nabla \varphi \cdot (p_t v_t) + \varphi \nabla \cdot (p_t v_t).$$

En intégrant cette identité sur $\mathbb{R}^d$, on obtient

$$\int_{\mathbb{R}^d} \nabla \cdot (\varphi(x) p_t(x) v_t(x)) dx = \int_{\mathbb{R}^d} \nabla \varphi(x) \cdot (p_t(x) v_t(x)) dx + \int_{\mathbb{R}^d} \varphi(x) \nabla \cdot (p_t(x) v_t(x)) dx.$$

Comme φ est à support compact, le champ $\varphi p_t v_t$ est également à support compact. Le théorème de Green implique alors que le terme de bord est nul, d’où

$$\int_{\mathbb{R}^d} \nabla \varphi(x) \cdot (p_t(x) v_t(x)) dx = - \int_{\mathbb{R}^d} \varphi(x) \nabla \cdot (p_t(x) v_t(x)) dx.$$

Ainsi,

$$\int_{\mathbb{R}^d} \varphi(x) \partial_t p_t(x) dx = - \int_{\mathbb{R}^d} \varphi(x) \nabla \cdot (p_t(x) v_t(x)) dx.$$

Par conséquent,

$$\int_{\mathbb{R}^d} \varphi(x) (\partial_t p_t(x) + \nabla \cdot (p_t(x) v_t(x))) dx = 0.$$

Comme cette égalité est vraie pour toute fonction $\varphi \in C_c^\infty(\mathbb{R}^d)$, on en déduit que

$$\partial_t p_t + \nabla \cdot (p_t v_t) = 0.$$

Les densités p_t et q_t satisfont donc la même équation de continuité avec la même condition initiale

$$p_0 = q_0.$$

Sous les hypothèses de régularité assurant l'unicité de la solution de l'équation de continuité associée au champ de vecteurs v_t , on obtient donc

$$p_t = q_t, \quad \forall t \in [0, T].$$

Les processus stochastiques $(\widehat{X}_t)_{t \in [0, T]}$ et $(\widehat{Y}_t)_{t \in [0, T]}$ possèdent donc les mêmes densités marginales. $\square$

Par convention de notation, $\forall x \in \mathbb{R}^d$, on notera dans la suite de ce document $\mathbb{E}_t[u_t(\widehat{X}_t) \mid \widehat{X}_t = x]$ à la place de $U_t(x)$. On a alors le corollaire :

Corollaire 6.4. *Soit $(\widehat{X}_t)_{t \in [0, 1]}$ le processus stochastique défini par l'interpolation linéaire*

$$\widehat{X}_t = (1 - t)\widehat{X}_0 + t\widehat{X}_1.$$

Ses trajectoires vérifient presque sûrement

$$\frac{d\widehat{X}_t}{dt} = \widehat{X}_1 - \widehat{X}_0.$$

On suppose que, pour tout $t \in [0, T]$, la variable aléatoire $\widehat{X}_t$ admet une densité marginale p_t suffisamment régulière. Soit $v_t : \mathbb{R}^d \rightarrow \mathbb{R}^d$ le champ de vecteurs déterministe défini presque partout comme l'espérance conditionnelle de la vitesse sachant la position x :

$$v_t(x) = \mathbb{E}_t[\widehat{X}_1 - \widehat{X}_0 \mid \widehat{X}_t = x].$$

Soit $(\widehat{Y}_t)_{t \in [0, 1]}$ la solution de l'équation différentielle ordinaire

$$\frac{d\widehat{Y}_t}{dt} = v_t(\widehat{Y}_t),$$

avec

$$\widehat{Y}_0 \sim \widehat{X}_0.$$

Alors, les processus stochastiques $(\widehat{X}_t)_{t \in [0, 1]}$ et $(\widehat{Y}_t)_{t \in [0, 1]}$ possèdent les mêmes densités marginales.

Démonstration. Il suffit d'appliquer le théorème 6.3 avec $u_t(\widehat{X}_t) = \widehat{X}_1 - \widehat{X}_0$ $\square$

Le terme $v_t(\widehat{x}_t) = \mathbb{E}_t[\widehat{x}_1 - \widehat{x}_0 \mid \widehat{x}_t] = \int_{\mathbb{R}^d \times \mathbb{R}^d} (\widehat{x}_1 - \widehat{x}_0) p_t(\widehat{x}_1, \widehat{x}_0 \mid \widehat{x}_t) d\widehat{x}_1 d\widehat{x}_0$ ne dépend alors plus d'une image générée $\widehat{x}_1$, puisque celle-ci est moyennée dans l'intégral. Conformément au schéma, l'EDO recherchée est donc :

$$\frac{d\widehat{x}_t}{dt} = v_t(\widehat{x}_t) \tag{13}$$

Ainsi, en intégrant entre $t = 0$ et $t = 1$ l'équation (13),

$$\widehat{x}_1 = \widehat{x}_0 + \int_0^1 v_t(\widehat{x}_t) dt \tag{14}$$

On pourrait alors penser que l'on peut générer des images $\hat{x}_1$ suivant approximativement la distribution $\mathbb{P}_{\text{data}}$ à partir d'images $\hat{x}_0$ et l'équation (14). Cependant, cette équation fait intervenir le champ de vitesses $v_t(\hat{x}_t)$, que l'on ne connaît pas.

En effet,

$$v_t(\hat{x}_t) = \int_{\mathbb{R}^d \times \mathbb{R}^d} (\hat{x}_1 - \hat{x}_0) p_t(\hat{x}_1, \hat{x}_0 \mid \hat{x}_t) d\hat{x}_1 d\hat{x}_0.$$

Or, d'après la formule de Bayes,

$$p_t(\hat{x}_1, \hat{x}_0 \mid \hat{x}_t) = \frac{p_t(\hat{x}_t \mid \hat{x}_1, \hat{x}_0) \pi(\hat{x}_1, \hat{x}_0)}{p_t(\hat{x}_t)},$$

où $\pi(\hat{x}_1, \hat{x}_0)$ désigne la loi jointe des couples $(\hat{x}_0, \hat{x}_1)$.

Le calcul exact de $v_t(\hat{x}_t)$ est donc impossible, car cette loi jointe est inconnue. Comme pour les modèles de diffusion, on entraîne alors un réseau de neurones afin d'approximer le champ de vitesses v_t .

6.1.2 Entraînement

On note $v_\theta : \mathbb{R}^d \times [0, 1] \rightarrow \mathbb{R}^d$ le réseau neuronal de paramètres θ , utilisé pour l'approximation. La difficulté principale réside dans le fait que le calcul exact du champ de vitesse $v_t(\hat{x}_t)$ est impossible en pratique : il dépend de la densité marginale p_t , qui elle-même découle de la distribution inconnue $\mathbb{P}_{\text{data}}$. Pour contourner ce problème et entraîner le réseau v_θ , la seule ressource dont nous disposons est notre ensemble d'images x_0 . La stratégie d'entraînement repose sur l'idée suivante : nous allons volontairement transporter des images $x_1 \sim \mathcal{N}(0, \lambda \cdot I)$ vers nos images x_0 . L'objectif du réseau v_θ sera d'apprendre à transporter x_1 vers nos images réelles $x_0 \sim \mathbb{P}_{\text{data}}$.

Dès lors, nous pouvons formaliser l'objectif d'entraînement de v_θ . Idéalement, nous souhaitons que $v_\theta(x_t, t)$ coïncide avec le véritable champ de vitesse $v_t(x_t)$ pour tout temps t . Cela se traduit par la minimisation de l'erreur quadratique suivante :

$$\mathbb{E}_t \mathbb{E}_{(x_0, x_1) \sim \pi} \mathbb{E}_{x_t \mid x_0, x_1 \sim \mathbb{P}_t} \left[\|v_\theta(x_t, t) - v_t(x_t)\|_2^2 \right] \quad (15)$$

où π correspond à un couplage quelconque et les images x_t sont les images intermédiaires entre x_1 et x_0 , de distribution $\mathbb{P}_t$.

L'optimisation de ce terme est l'étape clé du modèle FM. En effet, une fois le réseau entraîné, il suffit de substituer le champ de vitesse théorique inconnu par notre approximation $v_\theta(x_t, t)$ dans (14). On peut alors générer de nouvelles images $\hat{x}_1$ à partir d'images $\hat{x}_0 \sim \mathcal{N}(0, \lambda \cdot I)$ et (14). En pratique, minimiser directement l'équation (15) est impossible car le champ de vitesse $v_t(x_t)$ est inconnu. En revanche, le champ de vitesse conditionnel $u_t(x_t \mid x_1, x_0) = x_1 - x_0$ est parfaitement connu. L'enjeu est donc de reformuler cet objectif afin de faire apparaître ce champ de vitesse conditionnel. Ce passage crucial repose sur le théorème suivant :

Théorème 6.5. *[Conditional Flow Matching] Soit $(X_t)_{t \in [0, 1]}$ un processus stochastique à trajectoires absolument continues vérifiant*

$$\frac{dX_t}{dt} = X_1 - X_0,$$

On note

$$\mathcal{E}(\theta) = \mathbb{E}_t \mathbb{E}_{(X_0, X_1) \sim \pi} \mathbb{E}_{X_t \mid X_0, X_1 \sim \mathbb{P}_t} \left[\|v_\theta(X_t, t) - v_t(X_t)\|_2^2 \right]$$

Alors :

$$\mathcal{E}(\theta) = \mathbb{E}_t \mathbb{E}_{(X_0, X_1) \sim \pi} \mathbb{E}_{X_t \mid X_0, X_1 \sim \mathbb{P}_t} \left[\|v_\theta(X_t, t) - (X_1 - X_0)\|_2^2 \right] + C$$

où C ne dépend pas de θ .

6.1.3 Démonstration du Conditional Flow Matching

Pour démontrer le théorème, on a besoin du lemme suivant :

Lemme 6.6. *Soit $(X_t)_{t \in [0,1]}$ un processus stochastiques à trajectoires absolument continues vérifiant*

$$\frac{dX_t}{dt} = X_1 - X_0,$$

Alors

$$\mathbb{E}_t \mathbb{E}_{(X_0, X_1) \sim \pi} \mathbb{E}_{X_t | X_0, X_1 \sim \mathbb{P}_t} [(v_\theta(X_t, t) - v_t(X_t))^\top (v_t(X_t) - (X_1 - X_0))] = 0.$$

Démonstration. Pour cette démonstration, pour simplifier, on note $\mathbb{E}[\cdot]$ à la place de $\mathbb{E}_t \mathbb{E}_{(X_0, X_1) \sim \pi} \mathbb{E}_{X_t | X_0, X_1 \sim \mathbb{P}_t} [\cdot]$.

En utilisant (i) de la propriété 2.7, on obtient :

$$\mathbb{E}[(v_\theta(X_t, t) - v_t(X_t))^\top (v_t(X_t) - (X_1 - X_0))] = \mathbb{E}[\mathbb{E}[(v_\theta(X_t, t) - v_t(X_t))^\top (v_t(X_t) - (X_1 - X_0)) | X_t]].$$

De plus, le terme $v_\theta(X_t, t) - v_t(X_t)$ étant $\sigma(X_t)$ -mesurable, on a d'après (iii) de la propriété 2.7 :

$$\mathbb{E}[\mathbb{E}[(v_\theta(X_t, t) - v_t(X_t))^\top (v_t(X_t) - (X_1 - X_0)) | X_t]] = \mathbb{E}[(v_\theta(X_t, t) - v_t(X_t))^\top \mathbb{E}[v_t(X_t) - (X_1 - X_0) | X_t]].$$

Or, par linéarité de l'espérance,

$$\mathbb{E}[v_t(X_t) - (X_1 - X_0) | X_t] = \mathbb{E}[v_t(X_t) | X_t] - \mathbb{E}[X_1 - X_0 | X_t].$$

De plus, en utilisant (iii) de la propriété 2.7 avec $Y = 1_\Omega$, $\sigma(X_t)$ -mesurable et $U = v_t(X_t)$, on obtient

$$\mathbb{E}[v_t(X_t) | X_t] = v_t(X_t) \mathbf{1}_\Omega = v_t(X_t)$$

Ainsi, en remplaçant dans l'espérance, on obtient :

$$\mathbb{E}[(v_\theta(X_t, t) - v_t(X_t))^\top \mathbb{E}[v_t(X_t) - (X_1 - X_0) | X_t]] = \mathbb{E}[(v_\theta(X_t, t) - v_t(X_t))^\top (v_t(X_t) - \mathbb{E}[X_1 - X_0 | X_t])]$$

Or, par définition

$$v_t(X_t) = \mathbb{E}[X_1 - X_0 | X_t]$$

D'où

$$\mathbb{E}_t \mathbb{E}_{(X_0, X_1) \sim \pi} \mathbb{E}_{X_t | X_0, X_1 \sim \mathbb{P}_t} [(v_\theta(X_t, t) - v_t(X_t))^\top (v_t(X_t) - (X_1 - X_0))] = 0$$

□

On peut maintenant procéder à la démonstration du théorème 6.5 :

Démonstration. De la même manière que pour la démonstration du lemme 6.6, on note $\mathbb{E}[\cdot]$ à la place de $\mathbb{E}_t \mathbb{E}_{(X_0, X_1) \sim \pi} \mathbb{E}_{X_t | X_0, X_1 \sim \mathbb{P}_t} [\cdot]$.

$$\begin{aligned} \|v_\theta(X_t, t) - (X_1 - X_0)\|_2^2 &= \|v_\theta(X_t, t) - v_t(X_t) + v_t(X_t) - (X_1 - X_0)\|_2^2 \\ &= \|v_\theta(X_t, t) - v_t(X_t)\|_2^2 \\ &\quad + 2(v_\theta(X_t, t) - v_t(X_t))^\top (v_t(X_t) - (X_1 - X_0)) \\ &\quad + \|v_t(X_t) - (X_1 - X_0)\|_2^2. \end{aligned}$$

En prenant l'espérance, il vient

$$\begin{aligned}
& \mathbb{E} [\|v_\theta(X_t, t) - (X_1 - X_0)\|_2^2] \\
&= \mathbb{E} [\|v_\theta(X_t, t) - v_t(X_t)\|_2^2] \\
&\quad + 2 \mathbb{E} [(v_\theta(X_t, t) - v_t(X_t))^\top (v_t(X_t) - (X_1 - X_0))] \\
&\quad + \mathbb{E} [\|v_t(X_t) - (X_1 - X_0)\|_2^2].
\end{aligned}$$

Or, d'après le lemme 6.6, le terme croisé est nul. Il reste donc

$$\mathbb{E} [\|v_\theta(X_t, t) - (X_1 - X_0)\|_2^2] = \mathbb{E} [\|v_\theta(X_t, t) - v_t(X_t)\|_2^2] + \mathbb{E} [\|v_t(X_t) - (X_1 - X_0)\|_2^2].$$

En transposant on obtient

$$\mathbb{E} [\|v_\theta(X_t, t) - v_t(X_t)\|_2^2] = \mathbb{E} [\|v_\theta(X_t, t) - (X_1 - X_0)\|_2^2] + C,$$

où $C = -\mathbb{E} [\|v_t(X_t) - (X_1 - X_0)\|_2^2]$ ne dépend pas de θ . Donc,

$$\mathcal{E}(\theta) = \mathbb{E} [\|v_\theta(X_t, t) - (X_1 - X_0)\|_2^2] + C.$$

□

Par conséquent, (15) est égal à :

$$\mathbb{E}_t \mathbb{E}_{(x_0, x_1) \sim \pi} \mathbb{E}_{x_t | x_0, x_1 \sim \mathbb{P}_t} [\|v_\theta(x_t, t) - (x_1 - x_0)\|_2^2] + C \quad (16)$$

On définit alors la mesure de l'erreur commise par le réseau neuronal pendant l'entraînement, notée $\mathcal{L}(\theta)$, par $\mathcal{L}(\theta) = \mathbb{E}_t \mathbb{E}_{(x_0, x_1) \sim \pi} \mathbb{E}_{x_t | x_0, x_1 \sim \mathbb{P}_t} [\|v_\theta(x_t, t) - (x_1 - x_0)\|_2^2]$. Ainsi le terme à minimiser est d'après (16) :

$$\mathcal{L}(\theta) + C$$

De plus, puisque C ne dépend pas de θ , $\arg \min_\theta [\mathcal{L}(\theta) + C] = \arg \min_\theta [\mathcal{L}(\theta)]$.

Finalement, minimiser le terme :

$$\mathbb{E}_t \mathbb{E}_{(x_0, x_1) \sim \pi} \mathbb{E}_{x_t | x_0, x_1 \sim \mathbb{P}_t} [\|v_\theta(x_t, t) - v_t(x_t)\|_2^2]$$

est équivalent à minimiser le terme :

$$\mathbb{E}_t \mathbb{E}_{(x_0, x_1) \sim \pi} \mathbb{E}_{x_t | x_0, x_1 \sim \mathbb{P}_t} [\|v_\theta(x_t, t) - (x_1 - x_0)\|_2^2].$$

Ce qui d'après la loi des grands nombres, pour un ensemble de N images $\{x_0^{(1)}, \dots, x_0^{(N)}\} \subset \mathbb{R}^d$ suffisamment grand, correspond à minimiser :

$$\frac{1}{N} \sum_{i=1}^N \left\| v_\theta(t^{(i)}, x_t^{(i)}) - (x_1^{(i)} - x_0^{(i)}) \right\|_2^2,$$

l'expression obtenue ne dépend plus de p_{data} ni des images générées $\hat{x}_1$, mais seulement des images x_0 du jeu de données. On peut donc dorénavant entraîner le réseau neuronal v_θ à approximer v_t .

Il ne nous reste plus qu'à choisir le couplage π pour pouvoir générer des images.

Tout d'abord, pour pouvoir choisir le couplage π , on doit au préalable choisir la variance λ . Contrairement aux modèles SGM et Probability Flow, où λ était imposée par la méthode, la variance n'intervient pas dans le modèle FM, on peut donc choisir la valeur que l'on veut. On prend donc $\lambda = 1$ afin que les images $\hat{x}_0$ suivent la loi $\mathcal{N}(0, I)$.

On peut donc maintenant choisir le couplage π .

6.1.4 Couplage décorrélé

Le choix le plus naïf est de prendre des variables indépendantes, c'est-à-dire $\pi = \mathbb{P}_{\text{data}} \otimes \mathcal{N}(0, I)$. On peut alors implémenter le modèle.

On regarde alors si l'approximation du champ de vitesse v_t se déroule bien :




FIGURE 10 – Evolution des erreurs d'approximation du champ de vitesse.

La figure 10 montre que l'erreur relative présente un pic autour de $t = 0.89$. Ce phénomène ne traduit pas une mauvaise approximation du modèle, mais résulte de la définition même de l'erreur relative. En effet, lorsque la norme du champ de vitesse exacte $\|v(x_t, t)\|_2$ devient très faible, le dénominateur du rapport est proche de zéro, ce qui amplifie fortement l'erreur relative, même si l'erreur absolue $\|v_\theta(x_t, t) - v(x_t, t)\|_2$ reste faible. Il s'agit donc d'une instabilité numérique liée à la normalisation et non d'une dégradation des performances du modèle. Si on ne prend pas en compte la zone où la valeur du champ de vitesse est trop faible :




FIGURE 11 – Evolution des erreurs d'approximation du champ de vitesse (courbe ajustée).

On remarque alors avec la figure 11 que, sans compter la zone non représentée, l'erreur relative maximale est de 10%. L'approximation de v_t est donc correcte. On s'intéresse alors à la minimisation de $\mathcal{L}(\theta)$:




FIGURE 12 – Evolution de la moyenne de $\mathcal{L}(\theta)$.

On observe avec les figures 12 et 4 que la minimisation de $\mathcal{L}(\theta)$ se fait en moins d'itérations que celle de $L(\theta)$. En effet, la courbe de la figure 12 se stabilise à partir de 400 itérations tandis que la courbe de la figure 4 se stabilise à partir de 1200 itérations. On s'intéresse alors à la forme des trajectoires :




FIGURE 13 – Exemple de trajectoires de l'EDO avec le modèle FM.

On observe avec la figure 13 que, bien que les trajectoires de l'EDO soient nettement moins courbées que celles de la figure 9, elles ne sont pas, comme souhaité, des segments de droite. Cela s'explique par le fait que le réseau n'apprend pas directement la vitesse d'une trajectoire, mais son espérance conditionnelle. Ainsi, lorsque plusieurs trajectoires passent par une même image intermédiaire x_t , la vitesse apprise est une moyenne de plusieurs vitesses différentes et ne correspond plus exactement à la vitesse d'une trajectoire. Les trajectoires générées deviennent alors courbées.

Ces courbures traduisent le fait que le champ de vitesse appris est moins précis. Les images ne sont alors

plus transportées exactement selon les trajectoires souhaitées.

Une solution pour obtenir des trajectoires plus proches de segments consiste à utiliser un couplage corrélé permettant au réseau d'apprendre un champ de vitesse v_t plus simple et plus précis. Les images sont alors transportées de manière plus directe.

6.1.5 Couplage corrélé

La méthode **Optimal Flow Matching (OFM)** se distingue de la méthode FM par l'utilisation d'un couplage optimal, noté π^* . Le couplage π^* est obtenu en résolvant un problème de transport optimal. L'objectif est d'associer les images de départ et les images d'arrivée de manière à minimiser le coût du transport :

$$\mathbb{E}_{(x_0, x_1) \sim \pi} [\|x_1 - x_0\|_2^2] = \int_{\mathbb{R}^d \times \mathbb{R}^d} \|y - x\|_2^2 d\pi(x, y). \quad (17)$$

Sous les hypothèses du théorème de Brenier, ce problème admet une unique application de transport optimale, donnée par le gradient d'une fonction convexe. Les trajectoires obtenues par interpolation linéaire sont alors des segments de droite qui ne se croisent pas. Une même image intermédiaire x_t n'est donc plus traversée par plusieurs trajectoires de vitesses différentes. Le réseau apprend ainsi un champ de vitesse plus simple et plus précis.

On obtient alors que les trajectoires sont de la forme :




FIGURE 14 – Exemple de trajectoires de l'EDO avec la méthode OFM.

On remarque avec la figure 14 que les trajectoires obtenues avec la méthode OFM sont moins courbées que celles obtenues avec la méthode FM de la figure 13, mais qu'elles présentent encore de légères courbures. Celles-ci s'expliquent par le fait que, pour réduire le coût de calcul, l'algorithme couramment utilisé, appelé algorithme de Sinkhorn, fournit seulement une approximation du couplage optimal π^* . Les trajectoires obtenues ne sont donc pas exactement celles du véritable transport optimal et ne sont, par conséquent, pas parfaitement rectilignes.

En revanche, dans le cas d'un jeu de données simple, comme des gaussiennes, il est possible de calculer explicitement le couplage optimal π^* . On obtient alors les trajectoires suivantes :




FIGURE 15 – Exemple de trajectoires de l'EDO avec la méthode OFM (exacte).

On observe avec la figure 15 que les trajectoires obtenues sont de parfaits segments. On regarde alors la minimisation de $\mathcal{L}(\theta)$:




FIGURE 16 – Evolution de la moyenne de $\mathcal{L}(\theta)$ avec la méthode OFM.

Pour finir, on regarde si l'approximation du champ de vitesse v_t se déroule bien :




FIGURE 17 – Evolution des erreurs d'approximation du champ de vitesse avec la méthode OFM.

On remarque alors avec la figure 17 que l'erreur relative maximale est de 3%, l'approximation du champ de vitesse v_t est meilleure avec la méthode OFM qu'avec la méthode FM. L'approximation de v_t est donc bonne.

Toutefois, bien que l'algorithme de Sinkhorn réduise considérablement le coût de calcul par rapport à une résolution exacte du problème de transport optimal, son coût reste de l'ordre de $\mathcal{O}(N^2)$ par itération, où N désigne le nombre d'images du jeu de données. Ce coût peut rapidement devenir trop important lorsque le nombre d'images est élevé. En pratique, on approxime alors le couplage optimal π^* en utilisant une autre technique que le transport optimal.

6.1.6 Rectified Flow Matching

L'idée de la méthode **Rectified Flow Matching (RFM)** est de réitérer plusieurs fois la méthode FM afin d'obtenir des trajectoires se croisant de moins en moins. Pour cela, les images $x_1 \sim \mathcal{N}(0, I)$ sont conservées au cours des différentes itérations, tandis que les images du jeu de données sont progressivement remplacées par les images générées à l'itération précédente. Plus précisément, après une première génération des images $\hat{x}_{1,0}$ à partir des couples (x_1, x_0) , ces images deviennent les nouvelles données d'entraînement et permettent de générer un nouvel ensemble d'images $\hat{x}_{1,1}$. Ce procédé est répété autant de fois que souhaité. L'algorithme 1 résume les différentes étapes de cette méthode.

Algorithm 1 Rectified Flow Matching (RFM)

Require: Jeu de données $\{x_0^{(i)}\}_{i=1}^N$, images de bruit $\{x_1^{(i)}\}_{i=1}^N$, nombre d'étapes K

- 1: Initialiser $D_0 = \{x_0^{(i)}\}_{i=1}^N$
 - 2: **for** $k = 0, \dots, K - 1$ **do**
 - 3: Entraîner un modèle FM à partir des couples $(x_1^{(i)}, D_k^{(i)})$
 - 4: Générer un nouvel ensemble d'images $\hat{D}_{k+1}$ à l'aide du modèle entraîné
 - 5: Mettre à jour le jeu de données : $D_{k+1} \leftarrow \hat{D}_{k+1}$
 - 6: **end for**
 - 7: **return** Le dernier modèle entraîné.
-

À chaque étape, les images générées se rapprochent des images obtenues lors de l'étape précédente. Les couples utilisés pour l'entraînement deviennent ainsi progressivement plus cohérents, ce qui réduit les croisements entre les trajectoires.

On obtient alors que les trajectoires sont de la forme :




FIGURE 18 – Comparaison des trajectoires de l'EDO entre les méthodes FM et RFM.

On remarque alors avec la figure 18 que les trajectoires sont nettement plus linéaires avec la méthode RFM qu'avec la méthode FM.

On regarde alors la minimisation de $\mathcal{L}(\theta)$:




FIGURE 19 – Comparaison de l'évolution de la moyenne de $\mathcal{L}(\theta)$ entre les méthodes FM et RFM.

On observe alors avec la figure 19 qu'à partir de l'étape $k = 2$, la minimisation de $\mathcal{L}(\theta)$ avec la méthode RFM ne demande que très peu d'itérations.

Pour finir, on regarde alors si l'approximation du champ de vitesse v_t se déroule bien :




FIGURE 20 – Comparaison de l'évolution des erreurs absolues d'approximation du champ de vitesse entre les méthodes FM et RFM.




FIGURE 21 – Comparaison de l'évolution des erreurs relatives d'approximation du champ de vitesse entre les méthodes FM et RFM.

On observe sur la figure 21 que les erreurs relatives maximales sont respectivement de 0.7% et 0.2% pour la méthode RFM avec $k = 1$ et $k = 2$. La méthode RFM permet ainsi d'obtenir une approximation du champ de vitesse v_t plus précise que la méthode FM.

Par ailleurs, il a été démontré que sous certaines conditions sur le champ de vitesse v_t , lorsque le nombre d'étapes K devient grand, le couplage obtenu avec la méthode RFM converge vers le couplage optimal π^* de la méthode OFM [7]. En pratique, les différences de vitesse de génération et de qualité des images générées entre les deux méthodes proviennent essentiellement des paramètres d'entraînement, de l'architecture du réseau et des paramètres choisis.

Nous disposons désormais de l'ensemble des modèles étudiés. Il ne nous reste plus qu'à comparer leurs performances.

7 Comparaison des modèles

On compare maintenant les différents modèles. Cependant, les modèles approximent des éléments différents, on définit alors des critères permettant de comparer les modèles.

Negative Log-Likelihood (NLL). Le NLL mesure la capacité des différents modèles à approximer la distribution $\mathbb{P}_{\text{data}}$. Il est défini par

$$\text{NLL} = -\mathbb{E}_{x_0 \sim \mathbb{P}_{\text{data}}} [\log p_{\theta}(x_0)],$$

où $p_\theta(x_0)$ désigne la densité de probabilité du modèle évaluée en x_0 . Ainsi, plus la distribution apprise est similaire à la distribution $\mathbb{P}_{\text{data}}$, plus le modèle attribue une forte probabilité aux images x_0 du jeu de données et donc plus le terme $\log p_\theta(x_0)$ est grand. Ainsi plus le NLL est faible, plus la distribution de probabilité apprise est similaire à la distribution $\mathbb{P}_{\text{data}}$.

Fréchet Inception Distance (FID). Le FID mesure la ressemblance entre les images générées $\hat{x}_1$ et les images du jeu de données x_0 . Il est défini par

$$\text{FID} = \|\mu_{x_0} - \mu_{\hat{x}_1}\|_2^2 + \text{Tr}\left(\Sigma_{x_0} + \Sigma_{\hat{x}_1} - 2(\Sigma_{x_0}\Sigma_{\hat{x}_1})^{1/2}\right),$$

où μ_{x_0} et Σ_{x_0} désignent respectivement la moyenne et la covariance des caractéristiques (formes, textures, couleurs...) des images du jeu de données x_0 , tandis que $\mu_{\hat{x}_1}$ et $\Sigma_{\hat{x}_1}$ correspondent à celles des images générées. Ainsi, plus les images $\hat{x}_1$ et les images x_0 se ressemblent, plus les termes $\|\mu_{x_0} - \mu_{\hat{x}_1}\|_2^2$ et $\text{Tr}(\Sigma_{x_0} + \Sigma_{\hat{x}_1} - 2(\Sigma_{x_0}\Sigma_{\hat{x}_1})^{1/2})$ sont faibles. Par conséquent, plus le FID est faible, plus les images générées $\hat{x}_1$ sont visuellement proches des images du jeu de données x_0 .

Number of Function Evaluations (NFE). Le NFE correspond au nombre d'étapes de discrétisation utilisées lors de la résolution numérique de l'équation associé au processus de génération $(\hat{x}_t)_{t \in [0,1]}$. Plus le NFE est élevé, plus le pas de discrétisation est faible et donc plus la génération est lente. À l'inverse, un NFE faible permet de générer les images plus rapidement.

Par conséquent, plus les valeurs du NLL, du FID et du NFE sont faibles, plus le modèle est performant.

Pour évaluer les modèles, commençons par évaluer la qualité des images générées en calculant les moyennes des valeurs du FID et des valeurs du NLL pour chacun des modèles étudiés. Les résultats obtenus sont présentés dans le tableau :

Modèle	NLL	FID
SGM	2.5890	0.0904
Probability Flow	2.5890	0.0603
FM	2.5505	0.0174
OFM	2.5371	0.0127
RFM	2.6123	0.0186

TABLEAU 1 – Moyennes des valeurs de FID et de NLL pour un NFE constant égal à 100

On remarque avec le tableau 1 que, pour un NFE fixé à 100, les différents modèles présentent tous des valeurs de FID de l'ordre de 10^{-2} ainsi que des valeurs de NLL proches de 2.55. La qualité des images générées est donc globalement similaire pour l'ensemble des modèles. Le principal critère permettant de les départager est alors leur vitesse de génération.

Il est donc nécessaire d'étudier l'évolution conjointe du NLL et du FID en fonction du NFE. En effet, choisir un modèle uniquement en fonction de la rapidité avec laquelle il atteint sa valeur finale de FID ne garantit pas que sa NLL soit, à cet instant, suffisamment faible pour que la distribution des images générées soit proche de la distribution $\mathbb{P}_{\text{data}}$. Réciproquement, choisir un modèle uniquement en fonction de la rapidité avec laquelle il atteint sa valeur finale de NLL ne garantit pas que son FID soit, à cet instant, suffisamment faible pour que les images générées soient visuellement proches de celles du jeu de données.

Le modèle le plus performant est donc celui qui atteint, pour le plus petit NFE possible, des valeurs finales de NLL et de FID suffisamment faibles. Les figures suivantes présentent alors l'évolution des valeurs de NLL et de FID en fonction du NFE.




FIGURE 22 – Evolution de la moyenne des valeurs des NLL en fonction du NFE.




FIGURE 23 – Evolution de la moyenne des valeurs des FID en fonction du NFE.

Les figures 22 et 23 montrent que les différents modèles nécessitent des NFE différents pour atteindre leurs valeurs finales de NLL et de FID. On observe notamment que les modèles de Flow Matching requièrent moins d'évaluations que les modèles de diffusion. En particulier, les méthodes OFM et RFM atteignent leur valeur finale de NLL pour un NFE de l'ordre de la dizaine et leur valeur finale de FID pour un NFE de l'ordre de l'unité. Elles permettent ainsi de générer des images de bonne qualité plus rapidement que la méthode FM et que les modèles de diffusion.

Les différents modèles produisant des images de qualité comparable, les méthodes OFM et RFM apparaissent donc comme les plus performantes selon les critères retenus dans cette étude. Le choix entre ces deux approches dépendra alors principalement des contraintes de l'application considérée ainsi que des performances obtenues lors de l'entraînement.

En pratique, la méthode RFM est souvent privilégiée. En effet, quelques étapes suffisent généralement à obtenir des trajectoires proches de celles de l'OFM et des performances de génération similaires. Or, pour des jeux de données de grande taille, l'approximation du couplage optimal π^* par l'OFM est particulièrement coûteuse. La méthode RFM constitue ainsi un excellent compromis entre qualité de génération, vitesse de génération et coût d'entraînement.

8 Conclusion

Les modèles de diffusion ont marqué une étape majeure dans le développement des intelligences artificielles génératives. Grâce à leur capacité à produire des images de très grande qualité, ils ont été intégrés à de nombreux modèles génératifs. Leur principal inconvénient reste toutefois leur coût de génération, puisqu'ils nécessitent un grand nombre d'étapes pour produire une image.

Les méthodes de Flow Matching ont alors été développées afin de répondre à cette limitation. En apprenant directement un champ de vitesse reliant une distribution simple à la distribution des données, elles permettent de réduire considérablement le nombre d'étapes nécessaires à la génération tout en conservant une qualité d'image comparable.

Les résultats obtenus dans ce mémoire illustrent cette évolution. Les méthodes OFM et RFM produisent des images de qualité similaire à celles des modèles de diffusion, tout en nécessitant beaucoup moins d'évaluations du champ de vitesse. Elles offrent ainsi un excellent compromis entre qualité et rapidité de génération.

Cette évolution se retrouve aujourd'hui dans les intelligences artificielles génératives les plus récentes. Alors que DALL-E 2, Stable Diffusion 1 et Stable Diffusion XL reposaient sur des modèles de diffusion, les modèles plus récents comme Stable Diffusion 3 et FLUX.1 utilisent désormais le Flow Matching. Cette transition montre que le Flow Matching constitue aujourd'hui une évolution naturelle des modèles de diffusion et représente l'une des approches les plus prometteuses pour les futures intelligences artificielles génératives.

Paramètres

Code disponible sur : <https://github.com/MCOLIN29/-tude-des-mod-les-g-n-ratifs-pour-la-g-n-ration-d-images>

Paramètre	Valeur
<i>Distribution des données P_{data}</i>	
Gaussienne : type de distribution	Mélange de 8 gaussiennes 2D
Gaussienne : rayon des centres	$R = 4.0$
Gaussienne : écart-type de chaque mode	$\sigma_{\text{gaussienne}} = 0.3$
Spirale : type de distribution	Deux spirales 2D entrelacées
Spirale : nombre de bras	2
Spirale : angle maximal θ_{max}	4π
Spirale : coefficient d'expansion a	0.5
Spirale : écart-type du bruit ajouté	$\sigma_{\text{spirale}} = 0.15$
Dimension des données	$d = 2$
<i>Architecture des réseaux de neurones</i>	
Type	MLP entièrement connecté
Entrée	$(x, t) \in \mathbb{R}^d \times \mathbb{R}$
Couches cachées	3×128 neurones
Fonction d'activation	SiLU
Sortie	$\mathbb{R}^d$ (z_θ ou v_θ)
<i>Entraînement</i>	
Optimiseur	Adam
Taux d'apprentissage	2×10^{-3}
Gaussienne : taille de batch	512
Gaussienne : nombre d'itérations	4000
Spirale : taille de batch	1024
Spirale : nombre d'itérations	10 000
Nombre d'entraînements moyennés	10
SGM / Probability Flow : Bruit min. / max.	$\sigma_{\text{min}} = 0.01, \sigma_{\text{max}} \approx 9.684$
FM / OFM / RFM : Variance du bruit λ	1
<i>Spécificités par méthode</i>	
OFM : nombre d'images utilisées pour l'approximation du couplage optimal π^*	8 192
RFM : nombre de couples reconstruits à chaque étape	8 192
RFM : nombre d'entraînements moyennés	3
RFM : nombre d'étapes K	2
<i>Génération</i>	
Modèle SGM	Euler–Maruyama, 500 pas
Modèles Probability Flow / FM / OFM / RFM	Euler, 500 pas
Nombre d'échantillons générés	2000
<i>Comparaison des modèles</i>	
NFE par défaut	100
Nombre de NFE balayés	$\{5, 10, 20, 50, 100\}$
Nombre de répétitions de génération par NFE	10
Graine de génération	25
<i>Reproductibilité</i>	
Graine aléatoire globale	0

TABLEAU 2 – Paramètres de la distribution de données, des architectures et de l'entraînement utilisés

Bibliographie

- [1] Yang Song et Stefano Ermon, *Improved Techniques for Training Score-Based Generative Models*, Advances in Neural Information Processing Systems (NeurIPS), 2020.
- [2] Yang Song, Jascha Sohl-Dickstein, Diederik P. Kingma, Abhishek Kumar, Stefano Ermon et Ben Poole, *Score-Based Generative Modeling through Stochastic Differential Equations*, International Conference on Learning Representations (ICLR), 2021.
- [3] R. M. S. Rosa, *Reverse Flow*, Random Notes, 2024. Disponible sur : https://rmsrosa.github.io/random_notes/dev/generative/reverse_flow/.
- [4] Yaron Lipman, Ricky T. Q. Chen, Heli Ben-Hamu, Maximilian Nickel et Matt Le, *Flow Matching for Generative Modeling*, arXiv :2210.02747, 2023.
- [5] Xingchao Liu, Chengyue Gong et Qiang Liu, *Flow Straight and Fast : Learning to Generate and Transfer Data with Rectified Flow*, arXiv :2209.03003, 2022.
- [6] Chieh-Hsin Lai, Yang Song, Dongjun Kim, Yuki Mitsufuji et Stefano Ermon, *The Principles of Diffusion Models*, arXiv :2510.21890, 2025.
- [7] Leda Wang, Zhehao Xu, Qiang Liu et Harrison H. Zhou, *Computational and Statistical Guarantees of the c-Rectified flow*, arXiv :2608.02487, 2026.